TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN - ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH - VIỄN THÔNG

BÁO CÁO ĐỀ TÀI CUỐI KÌ

ỨNG DỤNG MẠNG NƠ-RON TÍCH CHẬP TRONG NHẬN DẠNG VÀ PHÂN LOẠI ẢNH PHỔ TÍN HIỆU RF

MÔN HỌC: HỌC MÁY VÀ TRÍ TUỆ NHÂN TẠO

GVHD: TS. HUỲNH THẾ THIỆN

Sinh viên thực hiện:

1. **GIANG VĨNH HUY** MSSV: 23119146
2. **PHẠM ĐÌNH PHƯỚC** MSSV: 23119197
3. **NGUYỄN QUANG NHƠN** MSSV: 23119184
4. **ĐOÀN NHẬT HOÀ** MSSV: 23119144
5. **NGUYỄN LÂM MINH NHẬT** MSSV: 23119183

TP. HỒ CHÍ MINH, 04/2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN - ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH - VIỄN THÔNG

BÁO CÁO ĐỀ TÀI CUỐI KÌ

ỨNG DỤNG MẠNG NƠ-RON TÍCH CHẬP TRONG NHẬN DẠNG VÀ PHÂN LOẠI ẢNH PHỔ TÍN HIỆU RF

MÔN HỌC: HỌC MÁY VÀ TRÍ TUỆ NHÂN TẠO

GVHD: TS. HUỲNH THẾ THIỆN

Sinh viên thực hiện:

1. **GIANG VĨNH HUY** MSSV: 23119146
2. **PHẠM ĐÌNH PHƯỚC** MSSV: 23119197
3. **NGUYỄN QUANG NHƠN** MSSV: 23119184
4. **ĐOÀN NHẬT HOÀ** MSSV: 23119144
5. **NGUYỄN LÂM MINH NHẬT** MSSV: 23119183

TP. HỒ CHÍ MINH, 04/2026

LỜI CẢM ƠN

Trong quá trình học tập và thực hiện đề tài "Ứng dụng mạng nơ-ron tích chập trong nhận dạng và phân loại ảnh phổ tín hiệu RF", nhóm thực hiện đã nhận được rất nhiều sự quan tâm, đóng góp ý kiến cũng như sự hỗ trợ tận tình từ các thầy cô, gia đình và bạn bè.

Trước hết, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy Huỳnh Thế Thiện. Với kiến thức chuyên môn sâu rộng và kinh nghiệm thực tiễn phong phú, Thầy đã định hướng cho nhóm trong việc lựa chọn phương pháp nghiên cứu phù hợp. Đồng thời, Thầy còn tận tâm hướng dẫn cách tiếp cận các mô hình học sâu, đặc biệt là mạng nơ-ron tích chập, một cách hiệu quả và có hệ thống.

Bên cạnh đó, những chia sẻ thực tế của Thầy về quá trình xây dựng, huấn luyện và đánh giá mô hình đã giúp nhóm rèn luyện tư duy thực tiễn khi triển khai một bài toán nhận dạng và phân loại ảnh bằng xử lý tín hiệu số. Nhờ sự dẫn dắt sát sao đó, mọi khó khăn vướng mắc dần được tháo gỡ, tạo tiền đề để tối ưu hóa mô hình và hoàn thiện hệ thống đúng với mục tiêu đã đề ra. Sự đồng hành và khích lệ từ Thầy chính là động lực to lớn mang đến thành công cho báo cáo này.

Đồng thời, chúng em cũng xin trân trọng gửi lời tri ân đến Ban Giám hiệu Nhà trường cùng quý thầy cô giảng dạy tại Khoa Điện - Điện tử. Những kiến thức nền tảng quý báu cùng một môi trường học tập, nghiên cứu đầy đủ tiện nghi chính là hành trang vững chắc tạo điều kiện thuận lợi nhất cho quá trình triển khai đề tài.

Mặc dù đã nỗ lực hết sức, nhưng do giới hạn về mặt thời gian và kinh nghiệm thực tiễn, báo cáo chắc chắn không thể tránh khỏi những thiếu sót. Kính mong nhận được sự góp ý và chỉ bảo thêm từ quý Hội đồng đánh giá cùng quý thầy cô để đề tài được hoàn thiện hơn, qua đó đúc kết thêm được những bài học quý báu cho chặng đường học tập và làm việc sau này.

Một lần nữa, chúng em xin chân thành cảm ơn!

Nhóm thực hiện đề tài
(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Tập thể nhóm thực hiện đề tài xin cam đoan đây là công trình nghiên cứu, tìm hiểu độc lập, được triển khai dưới sự hướng dẫn khoa học của TS. Huỳnh Thế Thiện. Các nội dung, số liệu và kết quả đánh giá mô hình được trình bày trong báo cáo là hoàn toàn trung thực, khách quan, tuyệt đối không sao chép từ bất kỳ đồ án hay dự án công trình nào khác trước đó. Mọi thông tin tham khảo từ các tài liệu, bài báo khoa học hay các nguồn tài nguyên trên internet đều được tổng hợp, trích dẫn rõ ràng, đầy đủ và minh bạch trong phần Tài liệu tham khảo. Chúng em xin chịu hoàn toàn trách nhiệm trước Hội đồng đánh giá và Nhà trường về tính trung thực của lời cam đoan này.

Nhóm thực hiện đề tài
(Ký và ghi rõ họ tên)

Mục lục

1 Giới thiệu **1**

1.1 Bối cảnh đề tài 1

1.2 Đặt vấn đề 1

1.3 Mục tiêu của đồ án 2

1.4 Bố cục của báo cáo 2

2 TỔNG QUAN TÀI LIỆU **3**

2.1 Từ Trích xuất Đặc trưng Thủ công đến Học sâu Truyền thống 3

2.2 Kiến trúc mạng Lightweight CNNs 4

2.3 Cơ chế tập trung (Attention Mechanisms) cho ảnh phổ 5

2.4 Kỹ thuật tối ưu hóa trên dữ liệu nhiễu cao 6

3 TẬP DỮ LIỆU **9**

3.1 Giới thiệu chung về tập dữ liệu và phương pháp biểu diễn phổ 9

3.2 Đặc điểm và phân loại tín hiệu 9

3.2.1 Nhóm tín hiệu Viễn thông (Telecommunications) 10

3.2.2 Nhóm tín hiệu Radar 10

3.3 Cấu trúc và quy định quản lý dữ liệu nguyên thủy 11

3.4 Chiến lược phân nhóm, ẩn tập thử nghiệm và tính tái lập 12

4 PHƯƠNG PHÁP NGHIÊN CỨU **13**

4.1 PHƯƠNG PHÁP NGHIÊN CỨU VÀ MÔ HÌNH ĐỀ XUẤT 13

4.1.1 Quy trình xử lý dữ liệu tổng quát 13

4.1.1.1 Các giai đoạn thực hiện chính 13

4.1.1.2 Chiến lược phân tách dữ liệu và Tính tái lập 15

4.2 Tiền xử lý và Tăng cường dữ liệu 15

4.2.1 Chuẩn hóa hình ảnh và Thích nghi môi trường vô tuyến 15

4.2.2 Chiến lược Tăng cường dữ liệu MixUp nâng cao 16

4.2.3 Tối ưu hóa hàm mất mát và Cơ chế Làm mượt nhãn 17

4.3 Kiến trúc mạng chuyên gia (Proposed BasicCNN) 18

4.3.1 Cấu trúc tổng thể mô hình 18

4.3.2 Khối Mobile Inverted Bottleneck (MBConv) 20

4.3.3 Cơ chế Coordinate Attention (CoordAtt) trong không gian ảnh phổ 21

4.3.4 Lớp Concat Pooling (Hybrid Feature Aggregation) 23
4.4 Chiến lược huấn luyện và Tối ưu hóa nâng cao 23
4.4.1 Cơ chế Trung bình động Lũy thừa (Exponential Moving Average - EMA) 24
4.4.2 Kỹ thuật Làm mượt nhãn - Label Smoothing 24
4.4.3 Tối ưu hóa hàm lỗi và Learning Rate Scheduler 25
4.5 Đóng gói và xuất mô hình 26
4.5.1 Cố định trạng thái suy luận 26
4.5.2 Trích xuất đồ thị tĩnh với kỹ thuật TorchScript Tracing 26
4.5.3 Quy chuẩn lưu trữ và Tính khả chuyển nhúng 27

5 THIẾT LẬP THỰC NGHIỆM 28
5.1 Môi trường và Thiết lập hệ thống 28
5.2 Hàm mất mát và Thuật toán tối ưu 29
5.2.1 Loss Cross-Entropy kết hợp Label Smoothing 29
5.2.2 Thuật toán tối ưu hóa AdamW 29
5.3 Tinh chỉnh tham số 30
5.4 Tinh chỉnh tốc độ học 32

6 KẾT QUẢ THỰC NGHIỆM 33
6.1 Quá trình hội tụ. 33
6.2 Đánh giá trên Validation Set. 34
6.3 Phân tích Confusion Matrix. 35
6.4 Phân tích Hiệu năng. 37

7 PHÂN TÍCH VÀ ĐÁNH GIÁ 39
7.1 Đánh giá hiệu suất mô hình 39
7.2 Phân tích biểu đồ 41

8 KẾT LUẬN 43

Danh mục bảng

5.1.1 Cấu hình phần cứng và phần mềm trên môi trường Kaggle 28
5.3.1 Tổng hợp cấu hình siêu tham số sử dụng trong quá trình huấn luyện 31

6.4.1 So sánh hiệu năng trực quan của 2 models 37
6.4.2 So sánh hiệu năng của 2 models 38

7.1.1 Phân tích các chỉ số trong quá trình huấn luyện 40
7.2.1 Tổng hợp hiệu suất phân loại của mô hình theo Confusion Matrix 42

Danh mục hình ảnh

2.1.1 Kiến trúc truyền thẳng tín hiệu qua Mạng nơ-ron tích chập (CNN) tiêu chuẩn [1] 4
2.2.1 Cơ chế nút thắt: (a) Residual block thông thường. (b) Inverted residual block của MobileNetV2 [2] 5
2.4.1 So sánh ranh giới quyết định giữa huấn luyện ERM truyền thống và phương pháp MixUp [3] 7
2.4.2 Kiến trúc mô hình EMA hoạt động như bộ lọc làm mượt học sâu [4] 7

3.2.1 Hình thái ảnh phổ của các phương thức điều chế viễn thông mẫu 10
3.2.2 Hình thái xung sắc nét đặc trưng của tín hiệu Radar trên ảnh phổ 11

4.1.1 Sơ đồ quy trình hệ thống đề xuất. 14
4.1.2 Đảm bảo tính tái lập 15
4.2.1 Quy trình tiền xử lý và thiết lập các thông số chuẩn hóa dữ liệu đầu vào thực thi trong mã nguồn. 16
4.2.2 Phân tích cơ chế nội suy tuyến tính giữa hình ảnh và nhãn trong kỹ thuật MixUp. 17
4.2.3 Hiện thực hóa sự kết hợp giữa hàm mất mát MixUp và cơ chế làm mượt nhãn trong mã nguồn. 18
4.3.1 Sơ đồ cấu trúc tổng thể của kiến trúc BasicCNN đề xuất. 19
4.3.2 Cấu trúc luồng xử lý chi tiết bên trong khối Mobile Inverted Bottleneck (MBConv) . . . 20
4.3.3 Sơ đồ luồng dữ liệu và quá trình mã hóa không gian bên trong khối Coordinate Attention 22
4.4.1 Cấu trúc lớp ModelEMA với hệ số suy giảm được cấu hình trong mã nguồn. 24
4.4.2 Khởi tạo hàm mất mát với cơ chế Label Smoothing. 25
4.4.3 Cấu hình bộ tối ưu AdamW và lịch trình Cosine Annealing LR. 25
4.5.1 Quy trình đóng gói mô hình sử dụng kỹ thuật Tracing và Serialization. 26

5.2.1 Biểu đồ nhiệt (Heatmap) so sánh không gian siêu tham số giữa Adam truyền thống và AdamW. Trục tung biểu diễn tốc độ học khởi tạo, trục hoành biểu diễn hệ số suy giảm trọng số [5]. 30
5.4.1 Biểu đồ mô phỏng sự suy giảm của tốc độ học theo chiến lược Cosine Annealing 32

6.1.1 Biểu đồ accuracy và loss của training và validation. 33
6.2.1 Kết quả đánh giá trên tập Validation (Data Augmentation) 34
6.3.1 Confusion Matrix đối với Validation Set 36

Danh mục các từ viết tắt

Dưới đây là danh mục các từ viết tắt được sử dụng trong báo cáo.

Các từ viết tắt	**Định nghĩa**
AI	Artificial Intelligence
AMC	Automatic Modulation Classification
ANN	Artificial Neural Network
AWGN	Additive White Gaussian Noise
BN	Batch Normalization
CCE	Categorical Cross-Entropy
CNN	Convolutional Neural Network
CoordAtt	Coordinate Attention
CV	Computer Vision
DL	Deep Learning
EMA	Exponential Moving Average
ERM	Empirical Risk Minimization
GAP	Global Average Pooling
I/Q	In-phase and Quadrature
IoT	Internet of Things
IR	Intermediate Representation
JIT	Just-In-Time
LFM	Linear Frequency Modulation
LR	Learning Rate
MBConv	Mobile Inverted Bottleneck Convolution
ML	Machine Learning
PRNG	Pseudo-Random Number Generator
R&D	Research and Development
RF	Radio Frequency
RNN	Recurrent Neural Network
SE	Squeeze-and-Excitation
SGD	Stochastic Gradient Descent
SiLU	Sigmoid Linear Unit
SNR	Signal-to-Noise Ratio
STFT	Short-Time Fourier Transform

Chương 1

Giới thiệu

1.1 Bối cảnh đề tài

Trong sự phát triển mạnh mẽ của công nghệ giao tiếp không dây hiện đại, không gian điện từ ngày càng trở nên chật chội với vô số các loại tín hiệu phát ra từ nhiều nguồn khác nhau. Trong các hệ thống giám sát phổ tần, việc tự động nhận dạng loại tín hiệu đang tồn tại trong phổ tần là một bài toán quan trọng. Quá trình này không chỉ giúp quản lý và cấp phát tần số hiệu quả mà còn đóng vai trò then chốt trong an ninh quốc phòng và phát hiện các nguồn phát sóng trái phép[6].

Các tín hiệu vô tuyến này có thể đến từ nhiều nguồn khác nhau như hệ thống viễn thông, thiết bị không dây, hoặc hệ thống radar. Để giải quyết bài toán phức tạp này, các hệ thống giám sát hiện đại thường sử dụng các kỹ thuật học sâu để phân tích dữ liệu phổ và phân loại các loại tín hiệu khác nhau một cách tự động với độ chính xác cao[1]

1.2 Đặt vấn đề

Các tín hiệu vô tuyến thu thập được trong thực tế hiếm khi ở dạng lý tưởng mà thường bị suy hao và pha trộn với nhiễu môi trường (chỉ số Signal-to-Noise Ratio - SNR rất thấp). Để thuận tiện cho việc trích xuất đặc trưng, các tín hiệu này có thể được biểu diễn dưới dạng ảnh phổ thời gian - tần số (spectrogram). Đầu vào của hệ thống sẽ là một ảnh phổ và đầu ra là nhãn phân loại của tín hiệu đó.

Tuy nhiên, việc triển khai các mô hình học sâu để xử lý ảnh phổ trên các thiết bị biên (Edge Devices) hoặc các hệ thống nhúng đòi hỏi tài nguyên phần cứng phải được tối ưu hóa tối đa. Bài toán đặt ra là làm thế nào để xây dựng một mô hình mạng nơ-ron tích chập (CNN) vừa có khả năng phân tách ranh giới tín hiệu trong môi trường nhiễu nặng, vừa phải tuân thủ nghiêm ngặt giới hạn tài nguyên tính toán. Cụ thể, tổng số lượng trọng số (trainable parameters) của mô hình không được phép vượt quá 100.000 tham số. Đây là một thách thức kỹ thuật rất lớn đòi hỏi sự cải tiến sâu sắc về mặt kiến trúc mạng so với các mô hình nhận dạng ảnh thông thường.

1.3 Mục tiêu của đồ án

Đồ án tập trung vào việc xây dựng một mô hình học sâu nhằm phân loại tín hiệu viễn thông và radar dựa trên biểu diễn thời gian–tần số của tín hiệu RF. Các mục tiêu cụ thể bao gồm:

- Xây dựng quy trình hoàn chỉnh cho hệ thống học sâu từ tiền xử lý dữ liệu đến đánh giá mô hình.
- Phân tích và xử lý hiệu quả dữ liệu ảnh phổ tín hiệu vô tuyến.
- Thiết kế và huấn luyện mô hình có kích thước nhỏ gọn (dưới 100.000 tham số).
- Đạt độ chính xác phân loại trên 90%.
- Đánh giá hiệu năng thông qua các độ đo kỹ thuật và ma trận nhầm lẫn.

1.4 Bố cục của báo cáo

Để trình bày rõ ràng các phương pháp và kết quả đạt được, báo cáo này được tổ chức như sau:

- Chương 1 (Giới thiệu): Trình bày bối cảnh, đặt vấn đề và mục tiêu của đồ án.
- Chương 2 (Tổng quan tài liệu): Điểm qua các nghiên cứu, phương pháp và kiến trúc học sâu liên quan đến xử lý ảnh phổ.
- Chương 3 (Tập dữ liệu): Mô tả đặc điểm, cấu trúc và phân bố của tập dữ liệu hình ảnh phổ tín hiệu vô tuyến được sử dụng.
- Chương 4 (Phương pháp đề xuất): Trình bày pipeline tiền xử lý dữ liệu và kiến trúc mạng RF-SpectroNet được thiết kế cho bài toán.
- Chương 5 (Thực nghiệm): Mô tả cấu hình huấn luyện, các siêu tham số và các kỹ thuật được áp dụng.
- Chương 6 (Kết quả): Trình bày biểu đồ huấn luyện, ma trận nhầm lẫn và so sánh hiệu năng giữa các mô hình.
- Chương 7 (Thảo luận): Phân tích kết quả, đánh giá ưu điểm và hạn chế của phương pháp đề xuất.
- Chương 8 (Kết luận): Tóm tắt kết quả đạt được và đề xuất hướng phát triển trong tương lai.

Chương 2

TỔNG QUAN TÀI LIỆU

Qua những năm gần đây, bài toán nhận dạng và phân loại tín hiệu sóng vô tuyến đã có sức ảnh hưởng lớn đến nhiều ngành công nghiệp, từ các hệ thống quang phổ nhận thức dân sự đến điện toán vô tuyến quân sự viễn thông. Trong chương này, chúng tôi sẽ trình bày sự tiến hóa từ các kỹ thuật phân tích truyền thống cho đến các kiến trúc học sâu tiên tiến nhất, từ đó chứng minh tính cấp thiết và logic đằng sau việc xây dựng mô hình của đồ án.

2.1 Từ Trích xuất Đặc trưng Thủ công đến Học sâu Truyền thống

Trong giai đoạn đầu của lĩnh vực Phân loại Điều chế Tự động (Automatic Modulation Classification - AMC), các kỹ sư điện tử viễn thông thường phụ thuộc rất nhiều vào bước trích xuất đặc trưng thủ công (hand-crafted features). Các thuật toán phổ biến thường xoay quanh phân tích tính chu kỳ (Cyclic Spectral Analysis) hoặc tính toán các mô-men thống kê bậc cao (High-Order Cumulants) [6]. Mặc dù các công cụ toán học này hoạt động tốt trong điều kiện phòng thí nghiệm hoặc môi trường truyền dẫn lý tưởng, sức mạnh của chúng suy giảm nghiêm trọng khi đối diện với các kênh truyền thực tế, vốn luôn đồng hành cùng hiện tượng suy hao đa đường (Multifath fading) và tỉ số tín hiệu trên nhiễu biến động (Low SNR) [7].

Để phá vỡ giới hạn truyền thống, Học sâu (Deep Learning) đã tạo ra một cuộc cách mạng trong xử lý tín hiệu. O'Shea và cộng sự [1] là những người tiên phong chuyển đổi tư duy bài toán. Thay vì ép các kỹ sư phải tự tìm ra công thức toán lý tưởng, họ đã đề xuất sử dụng Mạng nơ-ron tích chập (CNN) để tự động hóa quá trình học đặc trưng.

Quy trình điển hình của Học sâu truyền thống thường bắt đầu bằng thao tác chuyển đổi tín hiệu từ miền Thời gian 1D nguyên thủy sang miền Thời gian–Tần số 2D thông qua phép Biến đổi Fourier ngắn hạn (STFT) trước khi đưa vào CNN.

$$X(m,\omega) = \sum_{n=-\infty}^{\infty} x(n)w(n-m)e^{-j\omega n} \tag{2.1}$$

Việc ánh xạ thành cấu trúc ảnh (Spectrogram) cho phép các mạng CNN truyền thống khai thác các bộ lọc chập (filters) hệt như quy trình phân loại ảnh trong Thị giác Máy tính (Computer Vision - CV).

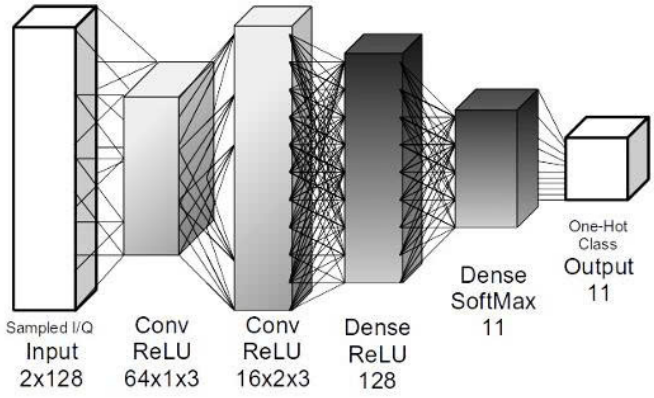

Hình 2.1.1: Kiến trúc truyền thẳng tín hiệu qua Mạng nơ-ron tích chập (CNN) tiêu chuẩn [1]

Dù Học sâu mang lại độ chính xác vượt trội so với các tham số thủ công, việc áp dụng các mạng CNN tiêu chuẩn (Standard CNNs) như VGG hay ResNet vào bài toán vô tuyến IoT vẫn tồn tại khuyết điểm chí mạng: Kích thước mô hình. Một mạng VGG-16 tiêu chuẩn yêu cầu tới xấp xỉ 138 triệu tham số (parameters). Sự bùng nổ về kích thước tensor làm tiêu tốn năng lượng phần cứng và băng thông bộ nhớ khủng khiếp cực kỳ không phù hợp với thiết bị viễn thông phần cứng nhỏ (Edge Devices) [8]. Hơn nữa, với các mạng khổng lồ này, hiện tượng quá khớp (Overfitting) xảy ra như một lẽ tất yếu khi tín hiệu bị che mờ trong môi trường Low SNR. Điều này trực tiếp vi phạm giới hạn thiết kế 100.000 tham số nghiêm ngặt do yêu cầu đồ án đặt ra. Mâu thuẫn trên thúc đẩy sự ra đời của các kiến trúc chuyên biệt nhỏ ngọn.

2.2 Kiến trúc mạng Lightweight CNNs

Để đáp ứng được giới hạn phần cứng nghèo nàn của vi điều khiển nhưng không làm mất đi năng lực xé rách nhiễu sóng của CNN, thuật toán Tích chập phân tách chiều sâu (Depthwise Separable Convolution) ra đời và định hình lại ngành trí tuệ nhân tạo.

Giải quyết trực diện bài toán tham số, Sandler và cộng sự [2] đã giới thiệu kiến trúc MobileNetV2. Phương pháp này phân rã một khối tích chập tiêu chuẩn tốn kém thành hai bước riêng biệt: tích chập theo không gian (depthwise convolution) trên từng kênh riêng lẻ và tích chập điểm (pointwise convolution 1×1) để trích xuất biểu diễn xuyên kênh (cross-channel).

Về mặt toán học, nếu một mạng CNN cổ điển (thảo luận ở phần 2.1) nhận đầu vào có kích thước không gian $D_F \times D_F$ với M kênh và muốn tạo ra N kênh đầu ra thông qua bộ lọc cốt lõi kích thước $D_K \times D_K$, số phép toán nhân cộng MAC (Multiply-Accumulate Operations) sẽ tỉ lệ thuận với biến:

$$C_{standard} = D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F \tag{2.2}$$

Ngược lại, với cấu trúc phân tách chiều sâu, chi phí tính toán được nén gọn lại thành:

$$C_{depthwise} = D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F \tag{2.3}$$

Thông qua một phép chia nhỏ, tỷ lệ tiết kiệm khối lượng tính toán và lượng tham số tối ưu đạt được là:

$$\text{Tỷ số tối ưu} = \frac{C_{depthwise}}{C_{standard}} = \frac{1}{N} + \frac{1}{D_K^2} \tag{2.4}$$

Với bộ lọc phổ quát nhất là màn lưới không gian 3×3 ($D_K = 3$), kỹ thuật này ép mô hình giảm đến $8 \sim 9$ lần dung lượng bộ nhớ tĩnh (ROM) và bộ nhớ RAM, mang lại giá trị thực tiễn vô cùng to lớn.

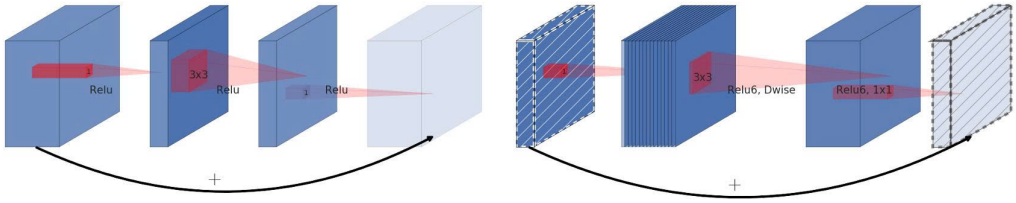

Hình 2.2.1: Cơ chế nút thắt: (a) Residual block thông thường. (b) Inverted residual block của MobileNetV2 [2]

Sự kết tinh giữa Depthwise Separable Convolution và thủ thuật mở kênh từ bên trong mạng gọi là Nút thắt đảo ngược (Inverted Residual). Thay vì nén số lượng đa kênh ở các lớp ẩn sâu như cấu trúc Residual cổ điển, Inverted residual phóng to số lượng kênh tại tầng giữa, sau đó chiếu ngược về trạng thái thắt nút trước khi qua hàm kích hoạt, tạo nên một cơ chế MBConv hoàn hảo. Thiết kế MBConv được đồ án đánh giá là cấu trúc khung xương (backbone) lý tưởng để thỏa mãn mọi ràng buộc của hệ thống nhận thức vô tuyến giới hạn biên.

2.3 Cơ chế tập trung (Attention Mechanisms) cho ảnh phổ

Khác với ảnh chụp thông thường (ví dụ: vật thể xe cộ, nhà cửa) mang tính đẳng hướng, đặc thù lớn nhất của dữ liệu chiều sâu vô tuyến được gắn cố định với hệ trục phi đẳng hướng: trục hoành X là chiều lăn của Thời gian (Time), trục tung Y là dải Tần số (Frequency). Mỗi dạng điều chế sẽ để lại một đặc tả hình học riêng rẽ.

Mạng nơ ron vốn rất "mù mờ"nếu không có cơ chế chú ý. Khi đối mặt với tín hiệu Radar băng rộng chạy dài ra nhiều cột hay viễn thông hẹp nằm ngang, các chuyên gia thường phải thiết kế cơ chế làm nổi bật (Attention mechanisms). Cơ chế phổ cập nhất quá khứ là Squeeze-and-Excitation (SE) [9]. Tuy nhiên, điểm lỗi thời lớn nhất của SE nằm ở trung bình hóa toàn cục (Global Average Pooling). Nó "đập bẹp"bức ảnh 224×224 trở thành 1 con số vô hướng duy nhất trên mỗi kênh. Hành động này vô tình xóa sổ hoàn toàn mọi toạ độ GPS định vị (Positional details) của dãy sóng - thứ đóng vai trò sự sống còn để nhận biết sóng radar nằm ở thời gian nào trong phổ.

Nhận thức được mức độ nghiêm trọng này, Hou và nhóm tác giả [10] đã giải phẫu cơ chế và định hình lại với phương pháp Điểm tập trung toạ độ (Coordinate Attention - CoordAtt). CoordAtt phân rã phép nén về một chiều nguyên lý (1D-pooling), thực hiện phép dóng thẳng song song trên từng cạnh của bức ảnh gốc $C \times H \times W$:

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq i < W} x_c(h, i) \tag{2.5}$$

$$z_c^w(w) = \frac{1}{H} \sum_{0 \leq j < H} x_c(j, w) \tag{2.6}$$

Sự tách rời này được đánh giá rất cao về mặt học thuật: mạng vừa biết được xung độ lớn cực đại ở thời điểm nào (phép dóng độ dài ngang W) vừa bảo tồn được phổ tần số tương đối (phép dóng độ dài H). Hai chuỗi số liệu được tích chập riêng rẽ và nhân trực diện lại vào bức ảnh gốc như một lớp mặt nạ chiếu sáng khu vực quan trọng (Attention Weights). Sự góp mặt của khối cấu trúc lai CoordAtt giải quyết bài toán gây hoang mang dư luận nhất của mạng Edge Devices: không chỉ duy trì sự gọn nhẹ, mô hình còn biết "chỉ đâu đánh đó"bỏ qua các pixel nhiễu hạt để tập trung dò theo hình thù dạng đường (Linear form).

2.4 Kỹ thuật tối ưu hóa trên dữ liệu nhiễu cao

Yếu tố khắc nghiệt cuối cùng đối với bài toán trong đồ án là mức độ hoang tàn của vùng nhiễu trắng hạt mịn cục bộ (White Noise).

- **MixUp Data Augmentation (Tăng cường dữ liệu nội suy)**: Zhang và cộng sự [3] đề xuất phương pháp MixUp, một bước tiến vượt xa nguyên lý Tối thiểu hóa rủi ro theo kinh nghiệm (Empirical Risk Minimization - ERM) truyền thống. Theo ERM, mạng nơ-ron học cách ghi nhớ các nhãn cứng (hard labels) của tập dữ liệu huấn luyện. Điều này vô tình khiến mô hình trở nên "tự tin thái quá"về các quyết định của mình và dễ sụp đổ khi gặp phải tín hiệu nằm ngoài phân phối gốc (ví dụ như tín hiệu bị méo mó nghiêm trọng do hiệu ứng Fading hay nhiễu AWGN).

  Để giải quyết vấn đề này, MixUp đề xuất mở rộng không gian huấn luyện bằng cách thực hiện nội suy tuyến tính (Linear Interpolation) cho cả dữ liệu không gian đầu vào lẫn nhãn phân loại. Giả sử hệ thống trích xuất ngẫu nhiên hai bức ảnh phổ từ tập dữ liệu là x_i, x_j cùng với các vector nhãn one-hot tương ứng của chúng là y_i, y_j, hệ thống sẽ tổng hợp ra một điểm dữ liệu ảo mới $(\tilde{x}, \tilde{y})$ thông qua công thức:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j \tag{2.7}$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j \tag{2.8}$$

  với $\lambda \in [0, 1]$ được lấy mẫu từ phân phối Beta.

  Kỹ thuật này ép mô hình làm nhòa đi ranh giới sắc nét gắt gao giữa các tập lớp (Class), thay vào đó tạo ra một dải viền chuyển tiếp mượt mà. Trong miền phân loại tín hiệu phổ vô tuyến, điều này có tính ứng dụng cực lớn: khi sự khác biệt giữa hình thái Radar và Viễn thông bị nhiễu

Published as a conference paper at ICLR 2018

```
# y1, y2 should be one-hot vectors
for (x1, y1), (x2, y2) in zip(loader1, loader2):
    lam = numpy.random.beta(alpha, alpha)
    x = Variable(lam * x1 + (1. - lam) * x2)
    y = Variable(lam * y1 + (1. - lam) * y2)
    optimizer.zero_grad()
    loss(net(x), y).backward()
    optimizer.step()
```

(a) One epoch of *mixup* training in PyTorch.

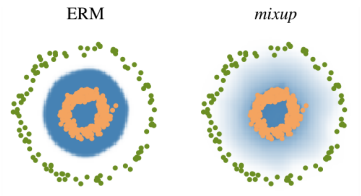

(b) Effect of *mixup* ($\alpha = 1$) on a toy problem. Green: Class 0. Orange: Class 1. Blue shading indicates $p(y = 1|x)$.

Hình 2.4.1: So sánh ranh giới quyết định giữa huấn luyện ERM truyền thống và phương pháp MixUp [3]

che lấp, MixUp giúp mô hình đi sâu vào việc phác họa các hình thái cấu trúc vật lý thực sự thay vì học vẹt vào các điểm pixel giả (noise artifacts), từ đó khôi phục lại tính bền vững mạnh mẽ cho hệ thống.

- **Exponential Moving Average (EMA)**: Bổ trợ song song cho hệ tính chống nhiễu loạn đồ hoạ, thì nhiễu miền tham số học liên tiếp lại là bài toán của Trọng lượng cục bộ (Weights). Trong điều kiện phân loại ảnh sóng gợn, gradient của trọng số (độ dốc vi phân) thường nhảy múa tán loạn, đặc biệt là ở những Epoch cuối làm mô hình không thể hội tụ độ chính xác cực đại. Khái niệm duy trì véc-tơ trung bình động EMA tạo thành điểm mỏ neo để kéo mô hình lại [4].

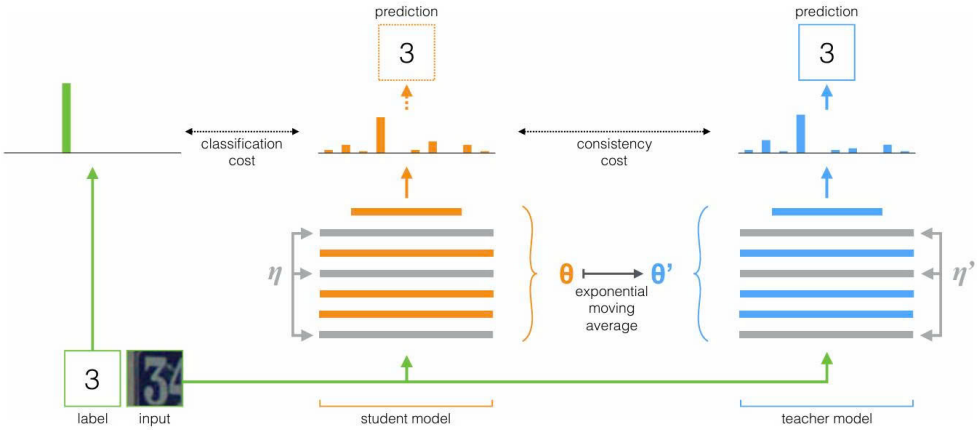

Hình 2.4.2: Kiến trúc mô hình EMA hoạt động như bộ lọc làm mượt học sâu [4]

Thuật toán định tuyến lại giá trị trọng số mới (đóng vai trò như Tín hiệu Thầy giáo - Teacher model) giữ lại mức biến đổi siêu nhỏ (Alpha model constraint):

$$\theta'_t = \alpha\theta'_{t-1} + (1 - \alpha)\theta_t \tag{2.9}$$

Theo đó Polyak-Ruppert Averaging giúp trọng số đi vào trạng thái hạ nhiệt (cooling down), ổn định và mượt mà hơn.

Tóm tắt kiến trúc mạng đề xuất: Từ những sai lầm truyền thống và những nguyên lý học thuật đỉnh cao được thiết kế nhằm sửa sai, đồ án này tự hào lựa chọn kiến trúc mạng hội tụ đầy đủ những tinh hoa học máy hiện tại. Mô hình đi từ cái nôi **MBConv** hạng nhẹ [2], vượt qua điểm mù vị trí nhờ **Coordinate Attention** [10], và trang bị khiên kháng nhiễu vĩnh cửu bởi **MixUp** [3] và **EMA** [4].

Chương 3

TẬP DỮ LIỆU

3.1 Giới thiệu chung về tập dữ liệu và phương pháp biểu diễn phổ

Trong các hệ thống giám sát phổ tần (Spectrum Monitoring Systems) hiện đại, khả năng phân tích và nhận dạng tự động các loại tín hiệu vô tuyến (Radio Frequency - RF) đóng một vai trò quyết định để duy trì sự ổn định của mạng viễn thông, chống nhiễu hoặc đánh chặn điện tử. Các tín hiệu này thường xuyên xuất hiện ngẫu nhiên từ nhiều nguồn khác nhau, điển hình như các trạm cơ sở viễn thông băng rộng, thiết bị dân dụng không dây, hoặc hệ thống radar quét mục tiêu quân sự [6].

Nhằm đáp ứng yêu cầu của đồ án, tập dữ liệu huấn luyện (training dataset) mang mã `training_dataset` đã được sử dụng. Đây là bộ dữ liệu chuẩn mực và độc quyền được cung cấp bởi Giảng viên hướng dẫn TS. Huỳnh Thế Thiện, với mục đích kiểm thử năng lực trích xuất đặc trưng của mạng nơ-ron học sâu [11]. Tập dữ liệu bao gồm tổng cộng 76.800 mẫu ảnh đầu vào. Điểm đặc biệt của tập dữ liệu này nằm ở phương pháp biểu diễn: thay vì sử dụng bộ dữ liệu chuỗi thời gian 1D (In-phase và Quadrature - I/Q samples) nguyên bản, toàn bộ tín hiệu RF trong bộ dữ liệu đã được áp dụng phép biến đổi Fourier ngắn hạn (Short-Time Fourier Transform - STFT) để tạo ra các ảnh phổ biểu diễn thời gian - tần số (Spectrogram images) [12]. Việc ánh xạ từ miền thời gian 1D sang phổ màu 2D giúp làm nổi bật kết cấu vi mô của các loại điều chế, tạo điều kiện thuận lợi để các kiến trúc Convolutional Neural Network (CNN) có thể nhận dạng mẫu (pattern recognition) tương tự như các bài toán thị giác máy tính truyền thống [**?**].

3.2 Đặc điểm và phân loại tín hiệu

Đầu vào của hệ thống học sâu là một ảnh phổ với kích thước không gian nhất định, mang nhiệm vụ phân loại tín hiệu thành 12 lớp (classes) chuyên biệt. Dưới lăng kính của biểu diễn tần số - thời gian, 12 đặc trưng này có hình thái hình học hoàn toàn tách biệt, được chia làm hai khuynh hướng chính: Tín hiệu Viễn thông và Tín hiệu Radar.

3.2.1 Nhóm tín hiệu Viễn thông (Telecommunications)

Nhóm tín hiệu Viễn thông chiếm đa số trong tập dữ liệu, bao gồm các phương thức điều chế biên độ, tần số và pha kỹ thuật số như: 16-QAM, B-FM, BPSK, CPFSK, DSB-AM, GFSK, PAM4, và QPSK.

Phân tích trên hình 3.2.1, có thể thấy đặc điểm chung của các tín hiệu viễn thông là sự duy trì năng lượng tần số liên tục trong một phổ thời gian dài. Do bản chất viễn thông cần truyền tải dữ liệu liên tục, ảnh spectrogram xuất hiện dưới dạng các khối rải dài theo chiều ngang, đôi khi che phủ toàn bộ dải băng thông hẹp của nó. Đối với các điều chế cao cấp như 16-QAM hay GFSK, đặc trưng mức nhảy tần và biến thiên pha tạo thành những vạch sóng mờ đan xen phức tạp [1].

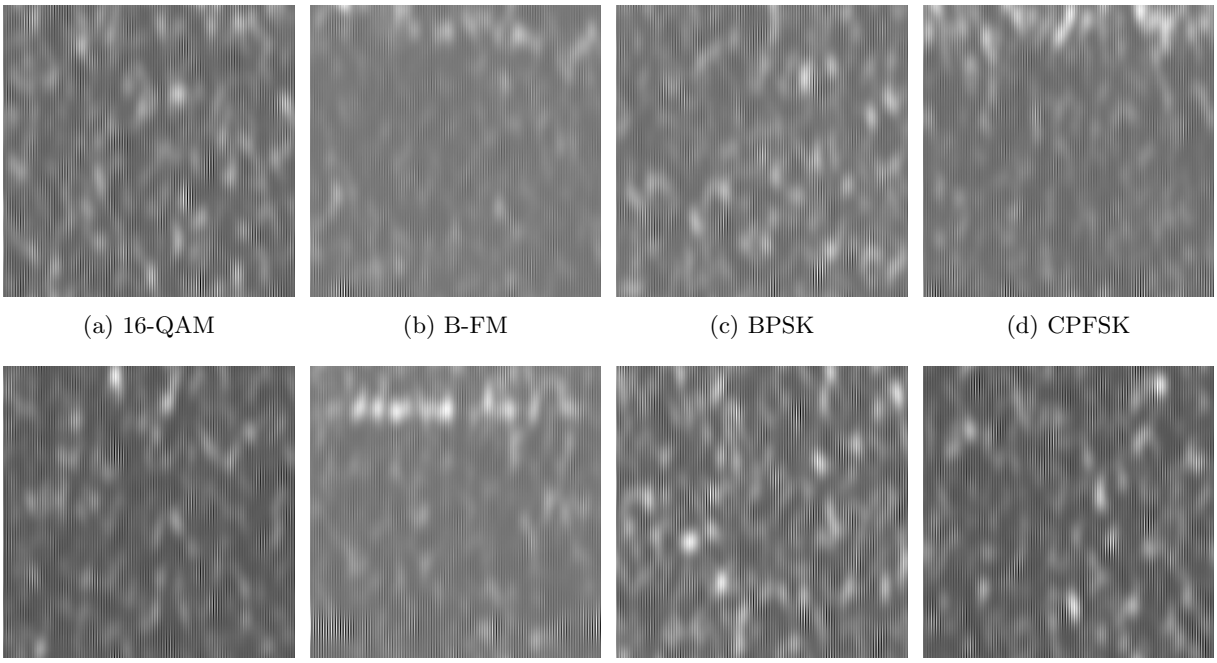

(a) 16-QAM (b) B-FM (c) BPSK (d) CPFSK

(e) DSB-AM (f) GFSK (g) PAM4 (h) QPSK

Hình 3.2.1: Hình thái ảnh phổ của các phương thức điều chế viễn thông mẫu

3.2.2 Nhóm tín hiệu Radar

Nhóm thứ hai là các tín hiệu phát xung đặc thù của Radar, bao gồm: Barker, LFM (Linear Frequency Modulation), Rect, và Step-FM.

Quan sát từ Hình 3.2.2, tín hiệu Radar có cấu trúc không gian cực kỳ sắc bén. Radar nguyên bản hoạt động dựa trên nguyên lý phát xung dò tìm dội lại, thời gian phát xung rất ngắn (nano hoặc micro giây) nhưng phải chớp nhoáng xé toạc toàn bộ dải băng thông. Điều này khiến cho trên biểu đồ Spectrogram, tín hiệu Radar in hằn thành các cột dọc mảnh, chóp nhọn xen kẽ với khoảng nghỉ tĩnh lặng, tạo thành sự đối lập hoàn toàn so với các vệt sáng ngang mờ ảo của nhiễu viễn thông.

Bên cạnh đặc tính dạng sóng, yếu tố tạo nên độ khó chuyên sâu (hard-mining) cho toàn bộ 12 class là sự xuất hiện dày đặc của tín hiệu nhiễu Gaussian trắng cộng dồn (AWGN - Additive White Gaussian Noise) và hiệu ứng suy hao đường truyền (Rayleigh fading). Sự tồn tại của các đốm nhiễu ngẫu nhiên làm xói mòn nghiêm trọng ranh giới nhận dạng của tín hiệu, đòi hỏi mạng CNN phải trang bị giải thuật

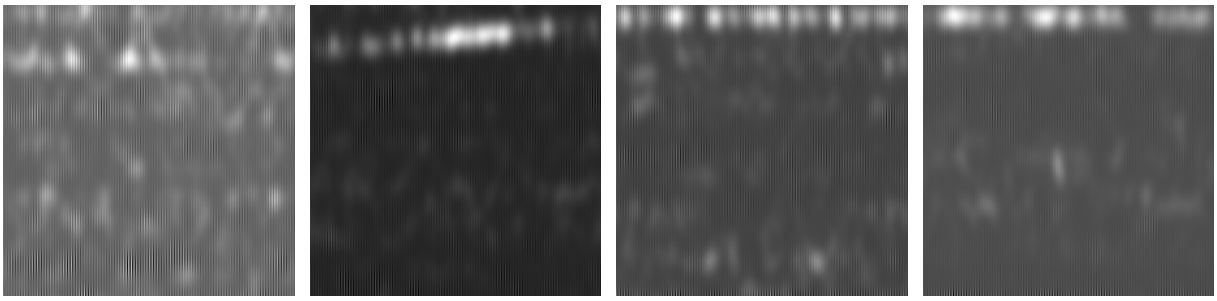

(a) Barker (b) LFM (c) Rect (d) Step-FM

Hình 3.2.2: Hình thái xung sắc nét đặc trưng của tín hiệu Radar trên ảnh phổ

lấy mẫu không gian và chú ý mạnh mẽ (như cơ chế Coordinate Attention) để tránh bị hiện tượng học vẹt các pixel nhiễu [10].

3.3 Cấu trúc và quy định quản lý dữ liệu nguyên thủy

Trong thiết kế công nghệ phần mềm thực tế, việc bảo toàn tính nguyên vẹn của bộ lưu trữ (Source of Truth) là một tiêu chuẩn tối quan trọng. Báo cáo này áp dụng chiến lược đóng băng tài nguyên ở cấp độ vật lý để đảm bảo môi trường phát triển nhất quán.

Theo quy định nghiêm ngặt của dự án, tập dữ liệu bắt buộc tuân thủ cấu trúc thư mục phân cấp cha - con (`dataset/class_1/`, `dataset/class_2/`...). Trong suốt quy trình thiết lập, nhóm đã áp dụng phương thức làm việc phòng vệ khắt khe:

- Cấm sửa đổi cấu trúc: Tuyệt đối cấm can thiệp trực tiếp để đổi tên class, cũng như thêm hay xóa bất kỳ thư mục con nào trên cây thư mục gốc.
- Cấm can thiệp độ phân giải gốc: Không tự ý resize hay crop hình ảnh làm suy giảm hoặc thay đổi kích thước quang học cục bộ. Do cấu trúc thiết kế của mô hình Convolutional được trói buộc bởi ma trận Tensor đa chiều, thông số định dạng không gian bắt buộc của đồ án được niêm yết ở ngưỡng ($C = 3, H = 224, W = 224$).

Thay vì chỉnh sửa trực tiếp, mọi phép tính tiền xử lý (như chuẩn hóa Standard Deviation, làm giàu dữ liệu Data Augmentation bằng ColorJitter hay Resize) được đẩy toàn bộ về vùng nhớ trong lúc biên dịch (Run-time). Mã nguồn tạo ra một quy trình ảo (pipeline) thông qua hàm `transforms.Compose` của thư viện torchvision, cho phép tensor ảnh được nhào nặn ngẫu nhiên theo mẻ (batch) ở tốc độ cao trên GPU, trong khi file gốc vẫn nằm yên tĩnh trên ổ cứng [13]. Đây là triết lý thiết kế tối thượng cho mọi quy trình huấn luyện thị giác máy tính hiện đại [2].

3.4 Chiến lược phân nhóm, ẩn tập thử nghiệm và tính tái lập

Một yếu tố cốt yếu trong học máy chuyên sâu (Deep Learning) là ngăn ngừa sự rò rỉ dữ liệu (Data Leakage) khi đánh giá. Phương pháp đo lường của đồ án được thiết kế chặt chẽ khi toàn bộ Tập kiểm thử (Test Set) bị giấu hoàn toàn trong suốt vòng đời nghiên cứu và thiết kế mô hình. Việc đánh giá năng lực cuối cùng sẽ do Giảng viên trực tiếp đưa "trọng số"của mô hình sinh viên nộp vào máy chấm độc lập để ghi nhận chỉ số thực.

Vì vậy, nhóm thực hiện chịu trách nhiệm phân tách 76.800 bức ảnh của tập hợp ban đầu thành 2 không gian con nội bộ để sử dụng thông qua tỷ lệ Pareto chuẩn:

- Tập huấn luyện (Training Set - 80%): Bao gồm số lượng mẫu khổng lồ nhất, đảm nhiệm vai trò nguồn cung đạo hàm để lan truyền ngược (Backpropagation) và cập nhật kiến trúc trọng số cho nơ-ron cục bộ.
- Tập kiểm chứng (Validation Set - 20%): Hoàn toàn bóc tách khỏi quá trình tính gradient. Tập dữ liệu này cung cấp một mỏ neo (Anchor) định lượng tính trạng thái thiên lệch quá khớp (Overfitting), đồng thời làm "còi báo động"hệ thống để lưu trữ lại bản sao trọng số hiệu quả nhất bằng kỹ thuật Checkpointing [3].

Để đảm bảo hiệu quả làm việc nhóm nhiều thành viên cũng như khả năng công chứng khoa học (Reproducibility), toàn bộ sự ngẫu nhiên trong hệ thống đã bị niêm phong bằng một khóa định tuyến (Random Seed). Hàm `set_seed(42)` được triển khai can thiệp sâu vào các engine của ngôn ngữ Python, Numpy và toàn bộ engine CUDA core trên card đồ họa của PyTorch [13]. Kết hợp cùng tỷ lệ 80/20, môi trường cô lập vô hình này đảm bảo tất cả các lần huấn luyện mô hình đều ra đúng một kịch bản dữ liệu lặp lại duy nhất, hoàn thiện sự liêm chính về học thuật của báo cáo.

Chương 4

PHƯƠNG PHÁP NGHIÊN CỨU

4.1 PHƯƠNG PHÁP NGHIÊN CỨU VÀ MÔ HÌNH ĐỀ XUẤT

4.1.1 Quy trình xử lý dữ liệu tổng quát

Trong nghiên cứu này, một quy trình xử lý dữ liệu toàn diện được thiết lập nhằm tối ưu hóa khả năng nhận diện tín hiệu radar và viễn thông từ các ảnh phổ spectrogram. Quy trình được thiết kế theo dạng chuỗi liên kết chặt chẽ (End-to-End Pipeline), đảm bảo dữ liệu được tinh lọc qua nhiều tầng trước khi đưa vào mô hình học sâu chuyên gia.

4.1.1.1 Các giai đoạn thực hiện chính

Toàn bộ hệ thống được vận hành dựa trên sáu giai đoạn chức năng chính, mỗi giai đoạn đóng vai trò quyết định đến độ chính xác và tính ổn định của mô hình:

1. **Giai đoạn 1 - Thu thập và Chuẩn hóa :** Dữ liệu đầu vào là tập hợp các hình ảnh phổ tín hiệu được tổ chức theo cấu trúc thư mục phân lớp, cho phép hệ thống tự động nhận diện số lượng các loại tín hiệu (classes) cần phân loại.
2. **Giai đoạn 2 - Tiền xử lý :** Hình ảnh thô trải qua bước chuẩn hóa kích thước về 224×224 pixels để tương thích với kiến trúc mạng. Đồng thời, các phép biến đổi về độ sáng, độ tương phản (ColorJitter) và chuẩn hóa phân phối pixel về miền $[-1, 1]$ được áp dụng nhằm giảm thiểu tác động của nhiễu môi trường.
3. **Giai đoạn 3 - Tăng cường dữ liệu :** Sử dụng thuật toán MixUp để tạo ra các mẫu dữ liệu tổng hợp. Kỹ thuật này giúp mô hình học được các ranh giới phân loại mềm mại giữa các dạng tín hiệu radar và viễn thông thông qua việc nội suy tuyến tính:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j \tag{4.1}$$

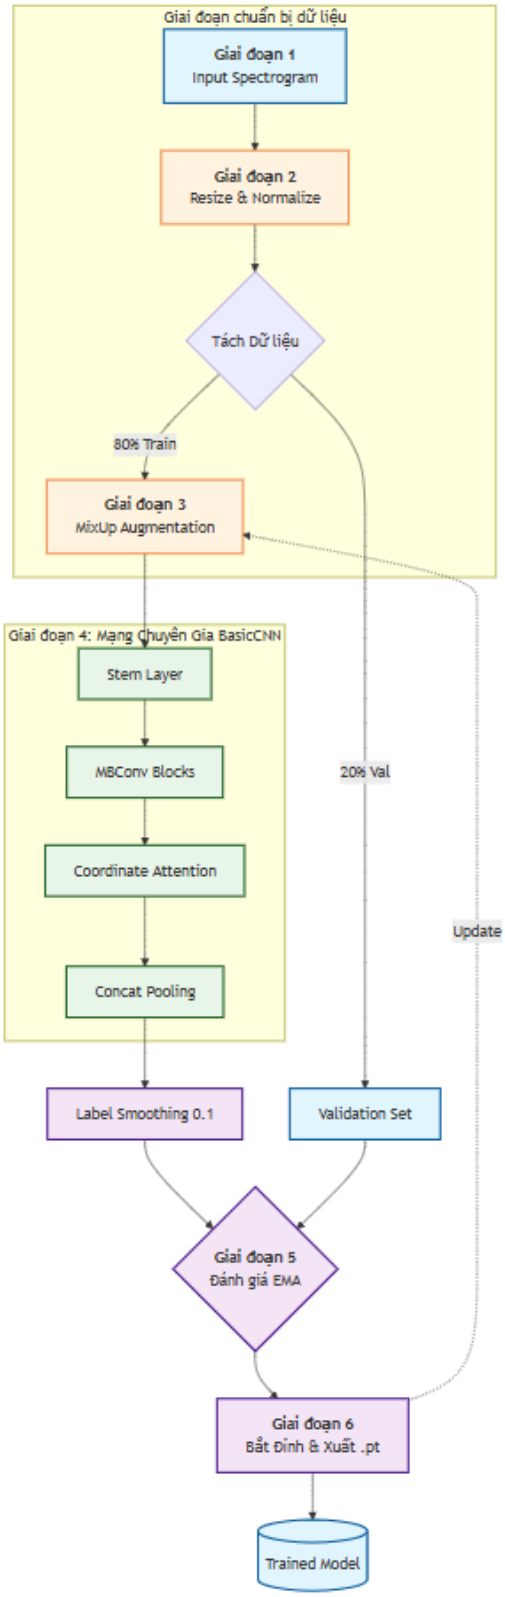

Hình 4.1.1: Sơ đồ quy trình hệ thống đề xuất.

4. **Giai đoạn 4 - Trích xuất đặc trưng:** Dữ liệu sau tăng cường được đưa qua mạng chuyên gia *BasicCNN*. Tại đây, các khối *MBConv* kết hợp cùng cơ chế *Coordinate Attention* sẽ lọc bỏ các thông tin dư thừa và tập trung vào các đặc trưng quan trọng theo chiều thời gian (ngang) và tần số (dọc).

5. **Giai đoạn 5 - Tối ưu hóa và Kiểm định:** Mô hình sử dụng kỹ thuật *Label Smoothing* để giảm sự tự tin thái quá vào nhãn nhiễu. Quá trình kiểm định thực hiện thông qua mô hình EMA (*Exponential Moving Average*) giúp làm mượt trọng số và bắt được điểm chính xác cao nhất (*Best Accuracy*).

6. **Giai đoạn 6 - Đóng gói và Xuất bản :** Trọng số tối ưu nhất được nạp ngược lại mô hình chính và thực hiện đóng gói bằng công nghệ *TorchScript*. Kết quả là tệp tin `.pt` sẵn sàng triển khai thực tế.

4.1.1.2 Chiến lược phân tách dữ liệu và Tính tái lập

Để đảm bảo tính khách quan và khoa học cho các kết quả thực nghiệm, chiến lược quản lý dữ liệu được thiết lập chặt chẽ như sau:

- **Phân chia tập dữ liệu:** Tập dữ liệu gốc được chia thành hai phần độc lập: Tập huấn luyện (*Training Set*) chiếm 80% và tập kiểm định (*Validation Set*) chiếm 20% dùng để đánh giá hiệu năng khách quan sau mỗi chu kỳ (epoch).
- **Đảm bảo tính tái lập (Reproducibility):** Một trong những yêu cầu quan trọng là khả năng lặp lại kết quả thực nghiệm. Do đó, tất cả các trình tạo số ngẫu nhiên (PRNG) được cố định bởi hạt giống số (*seed = 42*):

```python
def set_seed(seed=42):
    """Cố định tất cả các random seed để đảm bảo kết quả tái lập được"""
    random.seed(seed)
    np.random.seed(seed)
    torch.manual_seed(seed)
    if torch.cuda.is_available():
        torch.cuda.manual_seed(seed)
        torch.cuda.manual_seed_all(seed)
    torch.backends.cudnn.deterministic = True
    torch.backends.cudnn.benchmark = False

set_seed(42)
```

Hình 4.1.2: Đảm bảo tính tái lập

Việc này đảm bảo rằng các phép tách dữ liệu và khởi tạo trọng số mạng sẽ luôn đồng nhất trong mọi lần thực thi.

4.2 Tiền xử lý và Tăng cường dữ liệu

Trong nghiên cứu này, khâu tiền xử lý không chỉ đơn thuần là bước chuẩn bị mà còn đóng vai trò hạt nhân, quyết định trực tiếp đến khả năng hội tụ và độ chính xác phân loại cuối cùng của hệ thống. Đặc biệt, khi đối mặt với dữ liệu ảnh phổ tín hiệu có đặc thù là độ nhiễu nền lớn và sự chồng lấn tần số phức tạp, một quy trình tiền xử lý nghiêm ngặt là điều kiện tiên quyết. Quy trình được thiết kế nhằm mục tiêu kép: chuẩn hóa cấu trúc dữ liệu đầu vào để tương thích với mạng tích chập, đồng thời thực hiện chiến lược làm giàu tập huấn luyện thông qua các biến đổi toán học động, từ đó mở rộng biên độ chịu lỗi và triệt tiêu hiện tượng học vẹt vốn thường xảy ra với các tập dữ liệu tín hiệu vô tuyến giới hạn [14].

4.2.1 Chuẩn hóa hình ảnh và Thích nghi môi trường vô tuyến

Mọi ảnh phổ sau khi trích xuất từ các khung tín hiệu thời gian đều được đưa về một định dạng chuẩn chung nhằm đồng bộ hóa quy trình học đặc trưng của các bộ lọc tích chập. Bước này giúp loại bỏ các biến thiên không mong muốn về cường độ và kích thước vật lý của dữ liệu đầu vào:

- **Cấu hình và Tái cấu trúc kích thước dữ liệu:** Toàn bộ ảnh phổ được duy trì cố định ở kích thước 224×224 pixels thông qua tham số cấu hình. Việc lựa chọn độ phân giải này là kết quả của sự cân bằng tối ưu giữa việc bảo toàn các chi tiết đặc trưng tần số tinh vi và việc kiểm soát khối lượng tính toán trên thiết bị phần cứng.
- **Chuẩn hóa phân phối xác suất điểm ảnh:** Dữ liệu được đưa về miền giá trị $[-1, 1]$ với trung bình và độ lệch chuẩn đều bằng $0,5$ trên cả 3 kênh màu. Theo lý thuyết của Goodfellow và cộng sự, việc ép dữ liệu về một phân phối xác suất đồng nhất giúp bề mặt hàm mất mát trở nên trơn hơn, ngăn chặn hiệu quả hiện tượng bùng nổ hoặc biến mất cấu trúc đạo hàm. Điều này tạo điều kiện cho các thuật toán tối ưu hóa hội tụ nhanh chóng vào điểm tối ưu toàn cục [14].
- **Thích nghi biến động năng lượng tín hiệu:** Trong môi trường vô tuyến thực tế, cường độ tín hiệu thu nhận thường xuyên biến động do khoảng cách và các vật cản môi trường. Việc áp dụng biến đổi độ sáng và độ tương phản với biên độ $0,2$ đóng vai trò như một bộ giả lập nhiễu năng lượng động. Kỹ thuật này ép mô hình phải bỏ qua sự khác biệt về cường độ màu sắc để tập trung học sâu các cấu trúc hình học, hình dáng phổ và quy luật phân bổ thời gian - tần số đặc thù của từng loại tín hiệu [15].
- **Đa dạng hóa mẫu bằng phép lật đối xứng thời gian:** Phép lật ngang ngẫu nhiên tạo ra các biến thể đối xứng theo trục thời gian của tín hiệu. Điều này giúp mạng nơ-ron nhận diện được các đặc trưng sóng mang có tính tuần hoàn, từ đó tăng cường khả năng bao phủ của tập dữ liệu huấn luyện mà không cần tốn chi phí thu thập thêm mẫu thực tế ngoài môi trường.

```
transform = transforms.Compose([
    transforms.RandomHorizontalFlip(),
    transforms.ColorJitter(brightness=0.2, contrast=0.2),
    transforms.ToTensor(),
    transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))
])
```

Hình 4.2.1: Quy trình tiền xử lý và thiết lập các thông số chuẩn hóa dữ liệu đầu vào thực thi trong mã nguồn.

4.2.2 Chiến lược Tăng cường dữ liệu MixUp nâng cao

MixUp không chỉ đơn thuần là một kỹ thuật tăng cường dữ liệu mà là một phương pháp hiệu chỉnh dựa trên nguyên lý cực tiểu hóa rủi ro cấu trúc. Thay vì bắt mô hình phải học các ranh giới phân loại cứng nhắc và sắc lẹm, MixUp hướng mô hình đến việc hiểu bản chất chuyển đổi liên tục giữa các lớp tín hiệu thông qua các mẫu hỗn hợp ảo [3].

- **Nguyên lý nội suy tuyến tính:** Hệ thống thực hiện trộn lẫn ngẫu nhiên hai mẫu tín hiệu cùng các nhãn tương ứng để tạo ra mẫu ảo hỗn hợp. Về mặt toán học, điều này tạo ra một phân phối dữ liệu trung gian nằm giữa các cụm đặc trưng thực, giúp làm mịn không gian quyết định và giảm thiểu tính nhạy cảm của mô hình đối với các điểm dữ liệu nhiễu [**?**]:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j \tag{4.2}$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j \tag{4.3}$$

Trong đó, hệ số nội suy đóng vai trò là trọng số ảnh hưởng của mẫu gốc vào dữ liệu mới sinh ra.

- **Phân phối xác suất và Hệ số bao dung:** Tham số hệ số nội suy được lựa chọn dựa trên phân phối xác suất với giá trị $0, 2$. Với cấu hình này, hầu hết các mẫu sau khi trộn vẫn giữ được hình dáng đặc thù của lớp chính nhưng được pha thêm các nhiễu phổ của lớp phụ. Cơ chế này giúp mô hình trở nên bao dung hơn khi gặp các tín hiệu bị chồng lấn tần số hoặc tín hiệu yếu trong thực tế, nâng cao độ bền vững của hệ thống nhận diện [3].

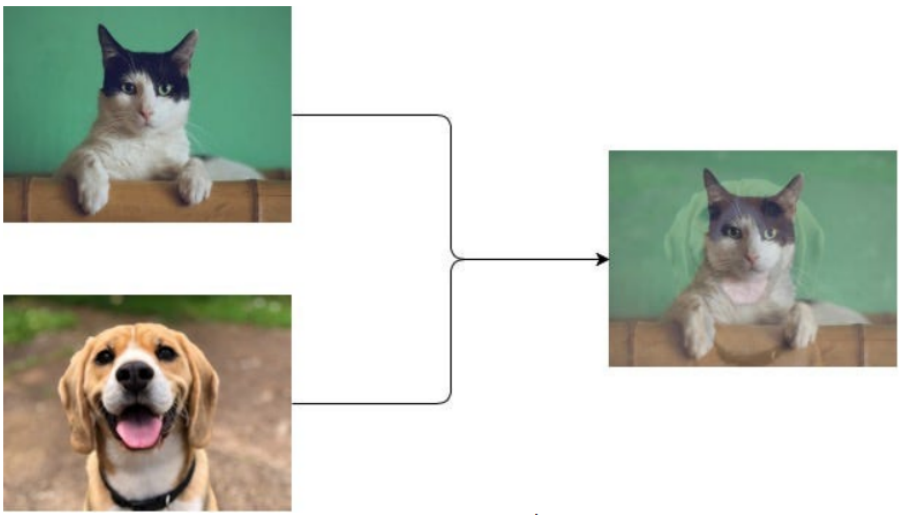

Hình 4.2.2: Phân tích cơ chế nội suy tuyến tính giữa hình ảnh và nhãn trong kỹ thuật MixUp.

4.2.3 Tối ưu hóa hàm mất mát và Cơ chế Làm mượt nhãn

Để tương thích hoàn toàn với dữ liệu đã được làm mềm bởi chiến lược MixUp, hàm mất mát của hệ thống cần được tái cấu trúc để phản ánh chính xác bản chất xác suất của dữ liệu đầu vào.

- **Chiến lược tính toán hàm mất mát hỗn hợp:** Thay vì tính toán hàm mất mát dựa trên một nhãn duy nhất, hệ thống sử dụng tổng trọng số của hai hàm mất mát thành phần tương ứng với hai nhãn gốc. Điều này ngăn chặn mô hình đưa ra dự đoán với xác suất quá tự tin, một trong những nguyên nhân chính khiến mô hình hoạt động kém khi gặp dữ liệu thực tế có nhiễu chồng lấn [**?**].
- **Kỹ thuật Làm mượt nhãn:** Trong phân loại tín hiệu vô tuyến, các nhãn đôi khi có sự nhập nhằng do nhiễu môi trường quá lớn. Bằng cách sử dụng hệ số làm mượt $0, 1$ tích hợp vào hàm mất mát, chúng ta phân bổ một lượng nhỏ xác suất cho toàn bộ các lớp còn lại thay vì dồn tuyệt đối vào một lớp đúng. Theo Szegedy và cộng sự, cơ chế này giúp thu hẹp khoảng cách giữa các cụm dữ liệu trong không gian đặc trưng, làm cho mô hình ít nhạy cảm hơn với các biến động phổ bất ngờ và nâng cao khả năng tổng quát hóa đáng kể [16].

```python
def mixup_criterion(criterion, pred, y_a, y_b, lam):
    return lam * criterion(pred, y_a) + (1 - lam) * criterion(pred, y_b)
```

Hình 4.2.3: Hiện thực hóa sự kết hợp giữa hàm mất mát MixUp và cơ chế làm mượt nhãn trong mã nguồn.

4.3 Kiến trúc mạng chuyên gia (Proposed BasicCNN)

Nhằm đáp ứng yêu cầu kỹ thuật khắt khe của đồ án là đạt độ chính xác phân loại tối thiểu 90% trong khi tổng số lượng tham số (trainable parameters) không được vượt quá giới hạn 100.000, nhóm nghiên cứu đã thiết kế một kiến trúc mạng tích chập tùy chỉnh có tên gọi là **BasicCNN**. Kiến trúc này là sự giao thoa giữa các cơ chế tối ưu dung lượng và các module tập trung trích xuất đặc trưng định hướng không gian.

4.3.1 Cấu trúc tổng thể mô hình

Cấu trúc của mạng BasicCNN được chia thành ba giai đoạn xử lý chính, tạo thành một luồng truyền dữ liệu (data flow) tuyến tính và tối ưu:

- **Khối Stem (Tầng gốc):** Tín hiệu đầu vào là ảnh phổ có kích thước $X \in \mathbb{R}^{3\times224\times224}$. Khối Stem sử dụng một lớp tích chập chuẩn (Conv2d) với kích thước kernel 3×3, bước trượt (stride) bằng 2, số lượng bộ lọc là 16. Tầng này có nhiệm vụ hạ lấy mẫu (downsample) độ phân giải không gian xuống còn 112×112 để giảm thiểu chi phí tính toán ban đầu, đồng thời trích xuất các dải màu và viền nhiễu cơ bản.
- **Chuỗi khối trích xuất đặc trưng (Body):** Là trái tim của mô hình, bao gồm 5 khối MBConvCA xếp chồng lên nhau. Số lượng kênh đặc trưng (feature channels) được mở rộng có chủ đích qua từng khối theo tiến trình: $16 \to 24 \to 40 \to 64 \to 80 \to 128$. Việc tăng dần số kênh giúp mạng học được các biểu diễn ngữ nghĩa trừu tượng hơn ở các tầng sâu.
- **Khối phân loại (Classifier Head):** Bản đồ đặc trưng (feature map) ở tầng cuối cùng có kích thước $128 \times 7 \times 7$. Thay vì dàn phẳng trực tiếp (flatten), dữ liệu được đi qua lớp Hybrid Concat Pooling, sau đó qua một lớp Dropout với tỷ lệ loại bỏ $p = 0.3$ nhằm chống quá khớp. Cuối cùng, một lớp kết nối đầy đủ (Fully Connected - FC) biến đổi vector đặc trưng 256 chiều thành các logit thô tương ứng với số lượng lớp tín hiệu.

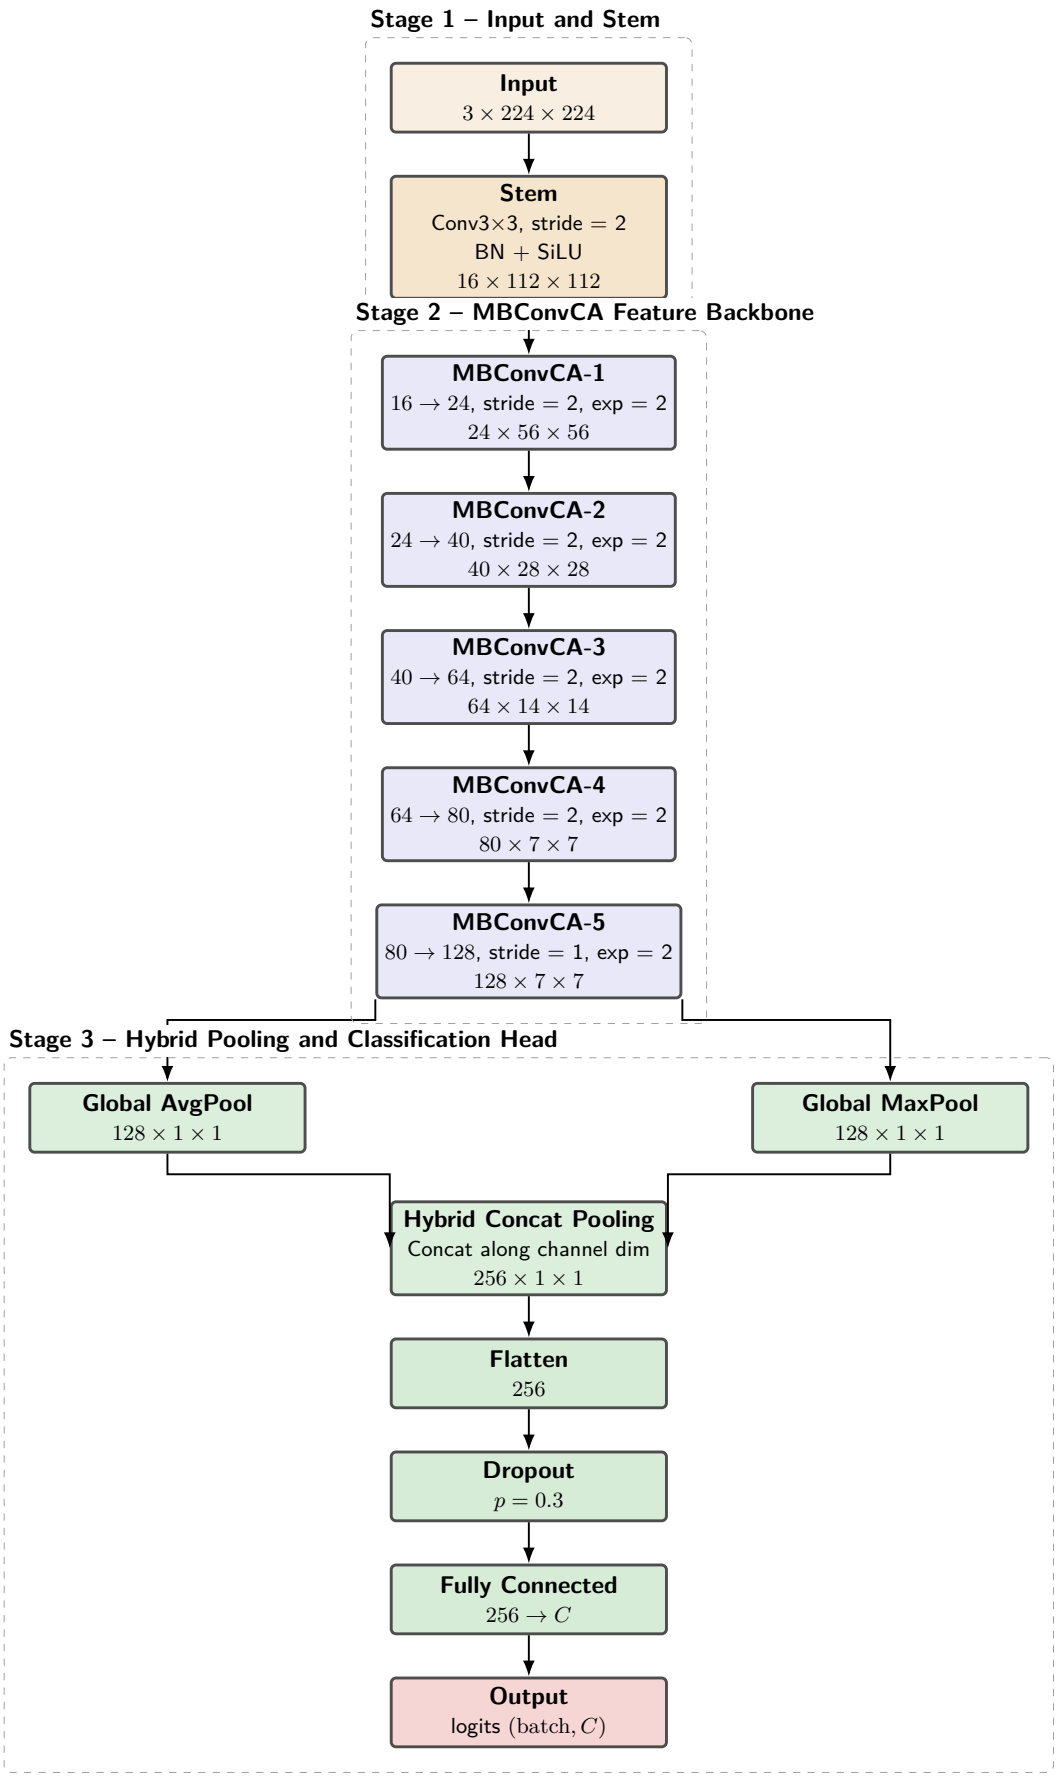

Hình 4.3.1: Sơ đồ cấu trúc tổng thể của kiến trúc BasicCNN đề xuất.

4.3.2 Khối Mobile Inverted Bottleneck (MBConv)

Khối MBConv được sử dụng làm thành phần xây dựng cơ bản (building block) nhằm duy trì độ sâu của mạng mà không làm "bùng nổ"số lượng tham số [2].

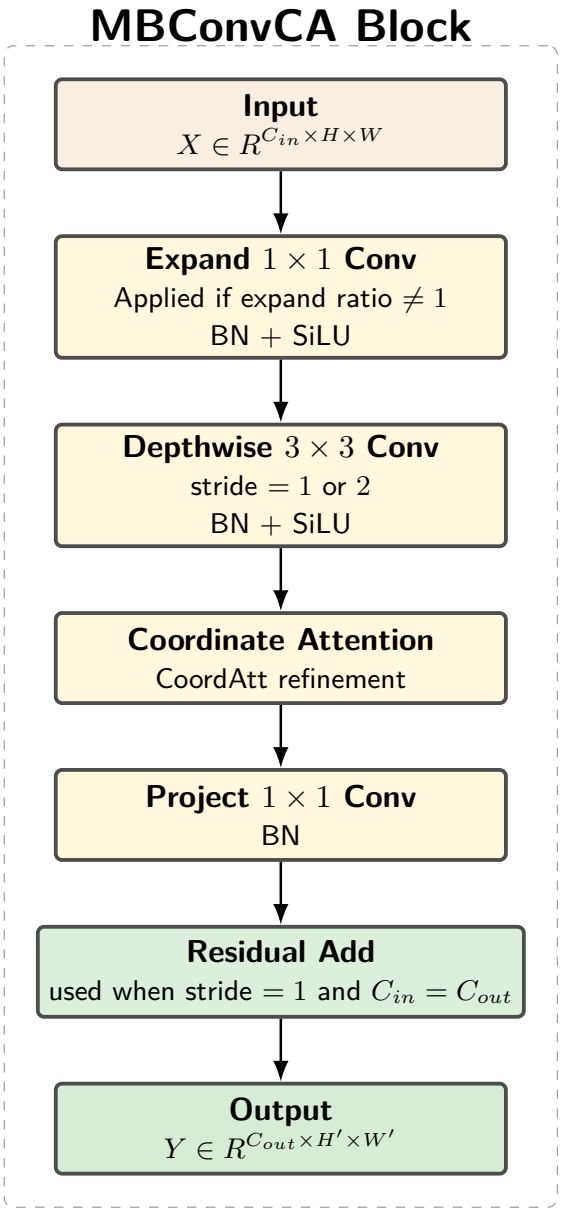

Hình 4.3.2: Cấu trúc luồng xử lý chi tiết bên trong khối Mobile Inverted Bottleneck (MBConv)

Như được minh họa chi tiết trong Hình 4.3.2, quá trình trích xuất đặc trưng và luân chuyển luồng dữ liệu bên trong khối MBConv được tối ưu hóa thông qua các cơ chế sau:

Lớp mở rộng kênh (Expand 1×1 Conv)Đầu vào của khối là một tensor đặc trưng $X \in \mathbb{R}^{C_{in} \times H \times W}$. Thay vì nén số kênh lại, khối MBConvCA bắt đầu bằng việc sử dụng một lớp tích chập 1×1 để mở rộng không gian chiều của đặc trưng lên t lần (với t là hệ số mở rộng, expand ratio). Bước này giúp mạng có không gian biểu diễn rộng hơn trước khi thực hiện lọc không gian. Lớp này đi kèm với Chuẩn hóa theo

lô (Batch Normalization - BN) và hàm kích hoạt phi tuyến SiLU.

Tích chập phân tách chiều sâu (Depthwise 3×3 Conv)Thay vì sử dụng lớp tích chập tiêu chuẩn tốn kém tài nguyên, mô hình áp dụng lớp Depthwise Conv với bộ lọc kích thước 3×3. Quá trình lọc dữ liệu được thực hiện bằng cách trượt các kernel trên từng kênh độc lập. Cơ chế phân tách này giúp tối ưu hóa số lượng tham số xuống hàng chục lần, là chìa khóa cốt lõi giúp kiến trúc mạng đạt được ngưỡng siêu nhẹ (dưới 100.000 tham số). Tương tự lớp mở rộng, đầu ra của lớp này cũng được đi qua BN và hàm kích hoạt SiLU. Nhóm lựa chọn SiLU với công thức:

$$f(x) = x \cdot \sigma(x) = \frac{x}{1 + e^{-x}}$$

nhờ đặc tính trơn và không đơn điệu, giúp luân chuyển gradient cực kỳ mượt mà qua các khối xếp chồng.

Cơ chế tinh chỉnh đặc trưng (CoordAtt Refinement)Ngay sau quá trình trích xuất không gian bằng Depthwise Conv, luồng dữ liệu được đưa qua module Coordinate Attention. Khác với các cơ chế chú ý kênh thông thường, block này trực tiếp mã hóa thông tin tọa độ không gian vào các tensor, giúp mạng tập trung vào các khu vực chứa tín hiệu quan trọng (sẽ được trình bày chi tiết ở mục 4.3.3).

Lớp nén kênh và Cổ chai tuyến tính (Project 1×1 Conv). Sau khi đặc trưng đã được tinh chỉnh, một lớp tích chập 1×1 (Pointwise Conv) được sử dụng để tổng hợp tuyến tính thông tin xuyên kênh và nén số lượng kênh từ không gian chiều cao về lại không gian chiều thấp (C_{out}). Đặc biệt, tại đây nhóm áp dụng thiết kế Cổ chai tuyến tính (Linear Bottleneck): lớp này chỉ sử dụng chuẩn hóa Batch Normalization mà loại bỏ hoàn toàn hàm kích hoạt phi tuyến. Việc không sử dụng SiLU ở bước cuối cùng nhằm ngăn chặn sự mất mát thông tin hữu ích khi tensor bị ép xuống số chiều nhỏ hơn.5. Kết nối thặng dư (Residual Add)Cuối cùng, nếu khối có bước nhảy $stride = 1$ và số kênh đầu vào bằng số kênh đầu ra ($C_{in} = C_{out}$), một kết nối tắt (skip-connection) sẽ cộng trực tiếp tensor đầu vào X với tensor sau lớp nén. Kết nối thặng dư này giúp giảm thiểu hiện tượng triệt tiêu đạo hàm (vanishing gradient) khi mạng huấn luyện ở các tầng sâu, cho ra bản đồ đặc trưng cuối cùng $Y \in \mathbb{R}^{C_{out} \times H' \times W'}$.

4.3.3 Cơ chế Coordinate Attention (CoordAtt) trong không gian ảnh phổ

Để giải quyết bài toán định vị đặc trưng tín hiệu, nhóm đã nhúng (embed) cơ chế Coordinate Attention trực tiếp vào bên trong mỗi khối MBConv (tạo thành module MBConvCA). Đối với bài toán ảnh phổ vô tuyến, thông tin vị trí không gian đóng vai trò tối quan trọng:

- Trục ngang (Thời gian): Sự xuất hiện của các vạch ngang kéo dài đại diện cho các tín hiệu Viễn thông (Telecom) duy trì phát sóng liên tục.
- Trục dọc (Tần số): Sự xuất hiện của các vạch dọc sắc nét, cường độ mạnh nhưng thời gian tồn tại ngắn đại diện cho các xung Radar có băng thông rộng.

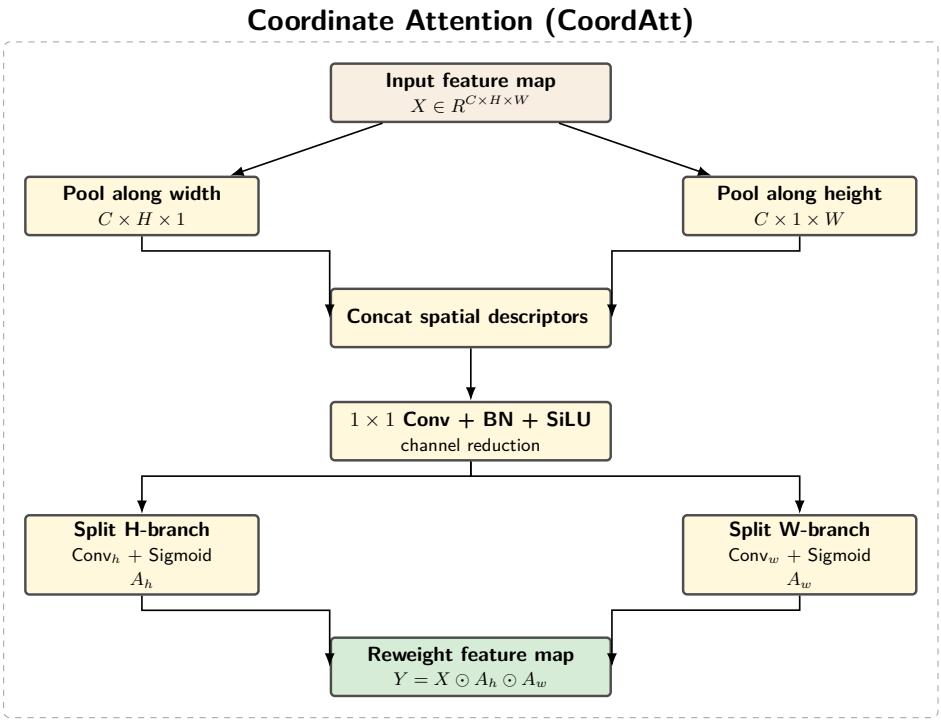

Hình 4.3.3: Sơ đồ luồng dữ liệu và quá trình mã hóa không gian bên trong khối Coordinate Attention

Như được minh họa chi tiết trong sơ đồ luồng dữ liệu (Hình 4.3.3), cơ chế CoordAtt giải quyết bài toán này bằng cách mã hóa thông tin kênh (channel) cùng với các tọa độ không gian dài hạn. Quá trình xử lý diễn ra qua các bước sau:

Phân rã không gian: Thay vì nén toàn bộ không gian 2D thành một vector duy nhất (như Squeeze-and-Excitation), bản đồ đặc trưng đầu vào $X \in \mathbb{R}^{C \times H \times W}$ được phân rã thành hai hướng. Khối thực hiện hai thao tác gộp (AdaptiveAvgPool2d) độc lập: gộp theo chiều rộng (Pool along width) để lấy thông tin trục Y tạo ra tensor $C \times H \times 1$, và gộp theo chiều cao (Pool along height) để lấy thông tin trục X tạo ra tensor $C \times 1 \times W$.

Kết hợp và nén kênh: Các bộ mô tả không gian 1D này sau đó được ghép nối lại với nhau (Concat spatial descriptors) dọc theo chiều không gian, rồi được biến đổi qua một khối bao gồm tích chập 1×1, chuẩn hóa Batch Normalization (BN) và hàm kích hoạt SiLU. Bước này giúp mạng tổng hợp thông tin giữa hai trục tọa độ và nén số lượng kênh (channel reduction) để giảm chi phí tính toán.

Tách nhánh và tạo trọng số: Tensor trung gian sau đó được tách ngược ra (Split) thành hai nhánh ngang (W-branch) và dọc (H-branch). Mỗi nhánh sẽ đi qua một lớp tích chập 1×1 riêng biệt ($Conv_h$ và $Conv_w$), theo sau là hàm kích hoạt Sigmoid để giới hạn giá trị trong khoảng $(0, 1)$. Kết quả thu được là hai tensor chú ý A_h và A_w chứa trọng số không gian độc lập.

Đánh trọng số lại: Dữ liệu đầu ra cuối cùng được tính toán bằng cách nhân chập theo phần tử (element-wise multiplication, ký hiệu $\odot$) giữa bản đồ gốc X với hai ma trận trọng số tọa độ này:

$$Y = X \odot A_h \odot A_w$$

Hay biểu diễn dưới dạng tọa độ điểm ảnh:

$$Y_c(i,j) = X_c(i,j) \times A_c^h(i) \times A_c^w(j)$$

Nhờ cơ chế này, mạng nơ-ron có thể "nhìn"và bám theo chính xác quỹ đạo của các vạch Radar và Viễn thông trên ảnh phổ dù bị nhiễu trắng che lấp.

4.3.4 Lớp Concat Pooling (Hybrid Feature Aggregation)

Ở chặng cuối của mạng trước khi đưa vào lớp phân loại, hầu hết các cấu trúc CNN chuẩn đều sử dụng bộ gộp trung bình toàn cục (Global Average Pooling - GAP). Tuy nhiên, qua quá trình phân tích đặc tính tín hiệu, nhóm nhận thấy GAP thường làm lu mờ các đỉnh năng lượng (energy peaks) của xung Radar.

Để khắc phục, nhóm đề xuất sử dụng kỹ thuật Hybrid Feature Aggregation, cụ thể là ghép nối trực tiếp (Concatenate) cả hai đặc trưng gộp:

1. Adaptive Average Pooling: Tính trung bình các giá trị trên bản đồ đặc trưng. Phép toán này ưu tiên bắt các nền tín hiệu ổn định, trải đều, vô cùng phù hợp để nhận dạng tín hiệu Viễn thông.
2. Adaptive Max Pooling: Chỉ trích xuất giá trị kích hoạt lớn nhất. Phép toán này phản ứng cực kỳ mạnh mẽ với các điểm ảnh có năng lượng đột biến, chính là "khắc tinh"để phát hiện ra các xung Radar sắc nét.

Hai tensor 128-chiều thu được từ quá trình này được ghép nối dọc theo trục kênh để tạo thành một vector biểu diễn 256-chiều duy nhất ($x = [x_{avg} \parallel x_{max}]$). Sự kết hợp bù trừ này đảm bảo mạng Classifier ở tầng cuối có đầy đủ manh mối để đưa ra quyết định phân loại, đóng góp không nhỏ vào kỷ lục hội tụ của hệ thống.

4.4 Chiến lược huấn luyện và Tối ưu hóa nâng cao

Quá trình huấn luyện một mạng nơ-ron sâu không chỉ đơn thuần là việc tính toán đạo hàm và cập nhật trọng số, mà thực chất là một bài toán điều hướng phức tạp trên không gian hàm mất mát (loss landscape) đa chiều siêu lớn. Đặc biệt, đối với tập dữ liệu tín hiệu vô tuyến (RF), nơi nhiễu môi trường và hiện tượng suy hao đa đường (multipath fading) làm mờ ranh giới giữa các lớp, việc chỉ sử dụng các phương pháp tối ưu hóa cơ bản thường dẫn đến hiện tượng hội tụ sớm tại các điểm tối ưu địa phương. Để mô hình *BasicCNN* đạt được sự hội tụ tối ưu nhất, nhóm nghiên cứu đã áp dụng một chiến lược huấn luyện đa tầng kết hợp các kỹ thuật điều chuẩn hiện đại, nhằm đảm bảo sự cân bằng hoàn hảo giữa khả năng khai phá (exploration) và tính ổn định (exploitation) [14].

4.4.1 Cơ chế Trung bình động Lũy thừa (Exponential Moving Average - EMA)

Trong quá trình tối ưu hóa bằng phương pháp giảm gradient theo lô nhỏ (Mini-batch Gradient Descent), đồ thị độ chính xác à hàm mất mát thường xảy ra hiện tượng dao động mạnh qua các chu kỳ. Nguyên nhân là do hướng cập nhật gradient phụ thuộc rất nhiều vào phân phối nhiễu của từng lô dữ liệu ngẫu nhiên. Để triệt tiêu hiện tượng này và tăng tính bền vững cho hệ thống, kỹ thuật *Model Shadow* dựa trên cơ chế Trung bình động Lũy thừa (EMA) theo lý thuyết của Polyak và Juditsky đã được thiết kế và tích hợp trực tiếp vào vòng lặp huấn luyện [17].

```
class ModelEMA:
    """Làm mượt trọng số chống rung lắc nhiễu"""
    def __init__(self, model, decay=0.999):
        self.ema = copy.deepcopy(model)
        self.ema.eval()
        self.decay = decay
        for p in self.ema.parameters():
            p.requires_grad_(False)

    def update(self, model):
        with torch.no_grad():
            for ema_v, model_v in zip(self.ema.state_dict().values(), model.state_dict().values()):
                if ema_v.dtype.is_floating_point:
                    ema_v.copy_(ema_v * self.decay + (1. - self.decay) * model_v)
```

Hình 4.4.1: Cấu trúc lớp ModelEMA với hệ số suy giảm được cấu hình trong mã nguồn.

Như thể hiện ở Hình 4.4.1, hệ thống không trực tiếp sử dụng mô hình đang huấn luyện để đánh giá (validation), mà duy trì một bản sao độc lập (được gọi là `self.ema`). Tại mỗi bước cập nhật gradient, trọng số của bản sao này không bị thay đổi đột ngột mà được cập nhật từ từ theo công thức toán học:

$$V_{EMA}^{(t)} = \alpha \cdot V_{EMA}^{(t-1)} + (1 - \alpha) \cdot V_{Model}^{(t)} \tag{4.4}$$

Với hệ số suy giảm (decay) $\alpha = 0.999$, mô hình EMA đóng vai trò như một bộ lọc thông thấp (low-pass filter) trên không gian trọng số: nó giữ lại tới $99,9\%$ tri thức từ lịch sử huấn luyện và chỉ tiếp thu $0,1\%$ trọng số mới. Sự "chậm rãi"có chủ ý này giúp mô hình triệt tiêu hoàn toàn các biến động nhiễu đột ngột từ các lô dữ liệu riêng lẻ, từ đó hệ thống có xu hướng hội tụ về các điểm cực tiểu phẳng (flat minima) — nơi mô hình có khả năng tổng quát hóa (generalization) mạnh mẽ nhất khi đối mặt với các tín hiệu RF chưa từng gặp trong thực tế [17].

4.4.2 Kỹ thuật Làm mượt nhãn - Label Smoothing

Hàm mất mát *Cross-Entropy* tiêu chuẩn kết hợp với nhãn cứng (Hard Label - ví dụ: $[1, 0, 0]$ cho lớp đúng) thường ép mạng nơ-ron phải đẩy giá trị dự đoán của lớp đúng tiến tới vô cùng để đạt được xác suất tuyệt đối 1.0. Trong bài toán phân tích phổ spectrogram, ranh giới giữa một số loại tín hiệu viễn thông thường rất mờ nhạt do sự chồng lấn dải tần. Việc ép mô hình phải quá tự tin - Overconfidence vào một dự đoán sẽ triệt tiêu khả năng học hỏi các ranh giới mềm, dẫn đến hiện tượng quá khớp - Overfitting[16].

```
criterion = nn.CrossEntropyLoss(label_smoothing=0.1)
```

Hình 4.4.2: Khởi tạo hàm mất mát với cơ chế Label Smoothing.

Để khắc phục rào cản này, hệ thống tích hợp tham số `label_smoothing=0.1` vào hàm mất mát. Kỹ thuật này, được giới thiệu lần đầu trong kiến trúc Inception [16], thực hiện phân bổ lại phân phối xác suất mục tiêu y_k:

$$y_k^{LS} = y_k \cdot (1 - \epsilon) + \frac{\epsilon}{K} \tag{4.5}$$

Trong đó, $\epsilon = 0.1$ là hệ số làm mượt và K là tổng số lớp. Thay vì đòi hỏi sự chắc chắn 100%, mô hình chỉ giữ lại 90% niềm tin cho nhãn ground-truth và chia đều 10% xác suất cho các lớp còn lại. Quá trình làm mượt này giúp ngăn chặn các trọng số nơ-ron phát triển quá lớn, co cụm các đặc trưng cùng lớp lại gần nhau hơn, đồng thời tạo ra một khoảng lề an toàn giữa các cụm phân loại, giúp hệ thống chịu lỗi tốt hơn trước các dữ liệu RF bị nhiễu.

4.4.3 Tối ưu hóa hàm lỗi và Learning Rate Scheduler

Thay vì giữ tốc độ học cố định (điều thường khiến mô hình bị mắc kẹt hoặc không thể hội tụ sâu), đồ án sử dụng một hệ thống tối ưu hóa kép, điều phối nhịp nhàng giữa thuật toán cập nhật gradient và lịch trình suy giảm học phí động.

```
optimizer = optim.AdamW(model.parameters(), lr=LEARNING_RATE, weight_decay=1e-2)
scheduler = CosineAnnealingLR(optimizer, T_max=EPOCHS, eta_min=1e-6)
```

Hình 4.4.3: Cấu hình bộ tối ưu AdamW và lịch trình Cosine Annealing LR.

- **Thuật toán AdamW (Adam with Decoupled Weight Decay):** Khác với thuật toán Adam truyền thống vốn gộp chung thành phần phạt L2 (L2 Regularization) trực tiếp vào tính toán gradient, hệ thống sử dụng `optim.AdamW` để tách biệt hoàn toàn quá trình này [18]. Với tốc độ học khởi điểm cực đại `lr=2e-3` và hệ số suy giảm trọng số `weight_decay=1e-2`, phương pháp tách biệt của AdamW ngăn chặn hiệu quả hiện tượng suy giảm sức mạnh của vector điều chuẩn. Điều này giúp kiến trúc sâu nhưng gọn nhẹ như BasicCNN duy trì được các giá trị trọng số ở mức nhỏ, ổn định và tránh bùng nổ tham số [18].
- **Lịch trình Cosine Annealing LR:** Tốc độ học được quản lý chặt chẽ bởi bộ lập lịch `CosineAnnealingLR` [19]. Trong suốt 80 chu kỳ (`T_max=EPOCHS`), tốc độ học không suy giảm theo một đường thẳng tuyến tính mà bám theo đường cong hình cosin, chạm đáy ở mức vi mô `eta_min=1e-6`. Ở những epoch đầu tiên, tốc độ học lớn cung cấp động năng để mô hình nhảy ra khỏi các hố tối ưu cục bộ. Càng về cuối chu kỳ, tốc độ học càng thu hẹp dần một cách mượt mà, cho phép mô hình thực hiện các tinh chỉnh vi mô (fine-tuning) để từ từ "định cư"tại điểm tối ưu sâu nhất mà không bị văng ra ngoài [19].

4.5 Đóng gói và xuất mô hình

Quá trình chuyển đổi từ môi trường nghiên cứu và phát triển (R&D) sang môi trường triển khai thực tế là bước ngoặt quyết định khả năng ứng dụng của dự án. Một mô hình đạt độ chính xác cao trên tập kiểm định vẫn có thể thất bại nếu không thể tích hợp vào các hệ thống phần cứng có tài nguyên hạn chế hoặc các phần mềm phân tích thời gian thực. Do đó, hệ thống áp dụng tiêu chuẩn đóng gói nghiêm ngặt dựa trên công nghệ *TorchScript* nhằm đảm bảo tính khả chuyển và tối ưu hóa hiệu năng suy luận [13].

4.5.1 Cố định trạng thái suy luận

Trước khi trích xuất kiến trúc, mạng nơ-ron *BasicCNN* phải được chuyển đổi dứt khoát từ trạng thái học tập sang trạng thái suy luận thông qua lệnh `model.eval()`. Thao tác này kích hoạt các thay đổi cốt lõi về luồng dữ liệu:

- **Vô hiệu hóa Dropout:** Lớp Dropout (tỷ lệ 0.3) sẽ ngừng hoạt động. Toàn bộ nơ-ron tham gia tính toán để trả về kết quả định lượng nhất quán thay vì ngẫu nhiên như pha huấn luyện.
- **Đóng băng Batch Normalization:** Các lớp chuẩn hóa lô sẽ ngừng cập nhật giá trị trung bình động. Thay vào đó, chúng sử dụng các tham số thống kê đã hội tụ sau 80 chu kỳ để chuẩn hóa phổ tín hiệu, giúp đầu ra mang tính tiền định tuyệt đối.

4.5.2 Trích xuất đồ thị tĩnh với kỹ thuật TorchScript Tracing

Thay vì lưu trữ dưới dạng *State Dictionary* (vốn đòi hỏi phải có mã nguồn định nghĩa lớp Python kèm theo), hệ thống sử dụng phương pháp *Tracing* thông qua hàm `torch.jit.trace`. Kỹ thuật này biên dịch mô hình động thành một đồ thị tính toán tĩnh (*Static Computation Graph*), độc lập hoàn toàn với trình thông dịch Python [20].

```
model.eval()
example_input = torch.randn(1, 3, IMAGE_SIZE, IMAGE_SIZE).to(DEVICE)
traced_model = torch.jit.trace(model, example_input)

GroupID = "09" # Đã điền Group ID của ông
model_name = f"{GroupID}_DeepLearningProject_TrainedModel.pt"
traced_model.save(model_name)
print("Model saved:", model_name)
```

Hình 4.5.1: Quy trình đóng gói mô hình sử dụng kỹ thuật Tracing và Serialization.

Dựa trên mã nguồn triển khai (Hình 4.5.1), quy trình này thực thi qua các bước kỹ thuật sau:

1. **Khởi tạo Tensor giả lập (Dummy Input):** Tạo một tensor ngẫu nhiên `example_input` định dạng $(1, 3, 224, 224)$. Đây là vector đại diện cho 1 mẫu tín hiệu, 3 kênh màu với kích thước chuẩn hóa 224×224.
2. **Ghi nhận luồng thực thi (Tracing):** Trình biên dịch JIT (*Just-In-Time*) bám theo vết của tensor qua từng lớp tích chập và khối *Coordinate Attention*. Mọi phép toán C++ bậc thấp được

ghi lại để tạo thành mã trung gian (*Intermediate Representation - IR*).

4.5.3 Quy chuẩn lưu trữ và Tính khả chuyển nhúng

Sản phẩm cuối cùng là tệp tin nhị phân `09_DeepLearningProject_TrainedModel.pt`. Khác với tệp `.pth` thông thường, tệp `.pt` đóng gói theo chuẩn JIT mang lại những ưu thế vượt trội:

- **Tối ưu hóa đồ thị:** JIT tự động thực hiện gộp toán tử, giúp mô hình chạy nhanh hơn đáng kể trên các thiết bị CPU/GPU đời mới.
- **Triển khai đa nền tảng:** Tệp này có thể được tải trực tiếp vào các ứng dụng C++ thông qua thư viện *LibTorch*, hoặc chạy trên các máy tính nhúng như NVIDIA Jetson Nano trong các trạm giám sát vô tuyến mà không cần cài đặt Python hay mã nguồn gốc.

Điều này mở ra tiềm năng ứng dụng thực tế rất lớn cho mô hình trong việc nhận diện và phân loại phổ tín hiệu RF trong môi trường tác chiến điện tử hoặc quản lý tần số dân dụng.

Chương 5

THIẾT LẬP THỰC NGHIỆM

5.1 Môi trường và Thiết lập hệ thống

Trong quá trình nghiên cứu và triển khai đề tài thì một trong những ưu tiên hàng đầu của nhóm là đảm bảo tính minh bạch và khả năng tái lập của toàn bộ hệ thống.

Để đáp ứng được cái yêu cầu thì toàn bộ quá trình xây dựng và huấn luyện và đánh giá mô hình sẽ được thực hiện trên môi trường lập trình Python, kết hợp với framework học sâu mã nguồn mở PyTorch. Do đặc thù của dữ liệu ảnh phổ và các phép toán ma trận phức tạp bên trong Mạng nơ-ron tích chập nên sử dụng GPU sẽ giúp cho tối ưu hàm mất mát và tốc độ cập nhật trọng số thông qua lan truyền ngược.

Bên cạnh phần cứng thì để triệt tiêu sự sai số ngẫu nhiên sinh ra trong quá trình khởi tạo tham số mạng và phân chia tập dữ liệu , nhóm đã thiết lập cố định các hạt giống ngẫu nhiên (random seed) ngay từ giai đoạn đầu của pipeline . Cụ thể, thông qua hàm định tuyến tùy chỉnh, hệ thống đã đồng bộ hóa seed (được chọn tĩnh là 42) cho toàn bộ các thư viện liên quan, bao gồm module random của Python, thư viện đại số Numpy, và các thuật toán tính toán song song trên GPU của thư viện cuDNN . Cơ chế kiểm soát chặt chẽ này đảm bảo rằng mọi thực nghiệm kiểm chứng mô hình đề xuất đều cho ra kết quả quỹ đạo huấn luyện (training trajectory) nhất quán ở mọi lần thực thi

Thành phần	**Cấu hình chi tiết**
Nền tảng thực nghiệm	Kaggle Notebook
Hệ điều hành	Linux 6.6.113+
CPU	Intel(R) Intel(R) Xeon(R) CPU @ 2.20GHz
RAM	31.35 GB
Bộ xử lý đồ họa (GPU)	NVIDIA RTX PRO 6000
Ngôn ngữ lập trình	Python 3.12.12
Pytorch	2.10.0+cpu

Bảng 5.1.1: Cấu hình phần cứng và phần mềm trên môi trường Kaggle

Như được thể hiện chi tiết trong Bảng 5.1.1, toàn bộ quá trình thực nghiệm được triển khai trên nền tảng máy ảo của Kaggle. Việc tận dụng bộ xử lý đồ họa NVIDIA RTX PRO 6000 giúp tối ưu hóa đáng kể thời gian huấn luyện cho mạng mạng tích chập đề xuất.

5.2 Hàm mất mát và Thuật toán tối ưu

Quá trình huấn luyện một mạng nơ-ron thực chất là bài toán tìm kiếm điểm cực tiểu của một hàm mục tiêu. Để mô hình BasicCNN đề xuất có thể hội tụ nhanh và đạt độ chính xác trên 90 với tập dữ liệu ảnh phổ RF, nhóm đã tinh chỉnh cẩn thận cả hàm mất mát (loss function) lẫn phương pháp cập nhật trọng số.

5.2.1 Loss Cross-Entropy kết hợp Label Smoothing

Đối với nhiệm vụ phân loại tín hiệu đa lớp (multi-class classification), hàm Cross-Entropy (CE) tiêu chuẩn là lựa chọn phổ biến nhất. Tuy nhiên, dữ liệu ảnh phổ vô tuyến trong thực tế thường chứa rất nhiều nhiễu nền (background noise) hoặc tín hiệu chồng lấp. Nếu sử dụng hàm CE gốc, mô hình sẽ có xu hướng ép các giá trị xác suất dự đoán tiến quá sát về 1 đối với nhãn đúng và 0 đối với nhãn sai. Hiện tượng này dẫn đến việc mô hình trở nên tự tin thái quá (overconfident) và rất dễ bị quá khớp (overfitting) với các nhiễu cục bộ trong tập huấn luyện.Để khắc phục triệt để vấn đề này, thay vì sử dụng CE thông thường, nhóm đã quyết định áp dụng kỹ thuật Làm mịn nhãn (Label Smoothing) được đề xuất bởi Szegedy và cộng sự [**?**]. Về mặt toán học, kỹ thuật này sửa đổi phân phối nhãn gốc (one-hot encoding) y_k thành một phân phối mới y_k^{LS} mềm mại hơn thông qua tham số làm mịn α:

$$y_k^{LS} = (1 - \alpha) \cdot y_k + \frac{\alpha}{K}$$

Trong đó, K là tổng số lớp tín hiệu cần phân loại, và α được nhóm thiết lập ở mức 0.1 thông qua thực nghiệm. Bằng cách phân bổ một lượng nhỏ xác suất $\frac{\alpha}{K}$ cho các lớp không chính xác, Label Smoothing ngăn chặn các logit của lớp mục tiêu phát triển quá lớn so với các lớp còn lại. Điều này ép mô hình phải chắt lọc các đặc trưng biểu diễn hình học thực sự của xung Radar hay Viễn thông, thay vì học vẹt các pixel nhiễu trắng.

5.2.2 Thuật toán tối ưu hóa AdamW

Lựa chọn thuật toán tối ưu đóng vai trò quyết định đến tốc độ hội tụ và chất lượng của điểm cực tiểu mà mô hình đạt được. Mặc dù Stochastic Gradient Descent (SGD) với Momentum truyền thống có khả năng tổng quát hóa tốt, nhưng lại đòi hỏi quá trình tinh chỉnh tốc độ học (learning rate) cực kỳ vất vả. Trong khi đó, thuật toán Adam thông thường tuy hội tụ nhanh nhưng lại xử lý cơ chế suy giảm trọng số (weight decay) không hiệu quả, dẫn đến kết quả kém trên các tập dữ liệu nhiễu.Chính vì lý do đó, hệ thống huấn luyện của đồ án sử dụng thuật toán AdamW (Adam with Decoupled Weight Decay) do Loshchilov và Hutter giới thiệu [5]. Điểm đột phá của AdamW là nó tách rời (decouple) hoàn toàn bước phạt trọng số (weight decay) ra khỏi quá trình tính toán vector gradient của hàm mất mát. Quá trình cập nhật tham số θ tại bước t được thực hiện theo nguyên tắc:

$$\theta_t = \theta_{t-1} - \eta_t \left(\alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda \theta_{t-1} \right)$$

Với η_t là tốc độ học (Learning Rate), $\hat{m}_t$ và $\hat{v}_t$ lần lượt là các moment bậc một và bậc hai đã qua hiệu chỉnh thiên kiến (bias-corrected), và λ là hệ số suy giảm trọng số.Trong đồ án này, nhóm thiết lập tốc độ học khởi tạo $LR = 2 \times 10^{-3}$ kết hợp với hệ số $weight_decay = 10^{-2}$. Sự kết hợp giữa AdamW và Label Smoothing không những giúp mạng MBConv tránh rơi vào các điểm cực tiểu cục bộ (local minima) tồi tệ, mà còn đảm bảo quỹ đạo huấn luyện diễn ra cực kỳ mượt mà, hạn chế tối đa các gai dao động (spikes) trong biểu đồ training loss.

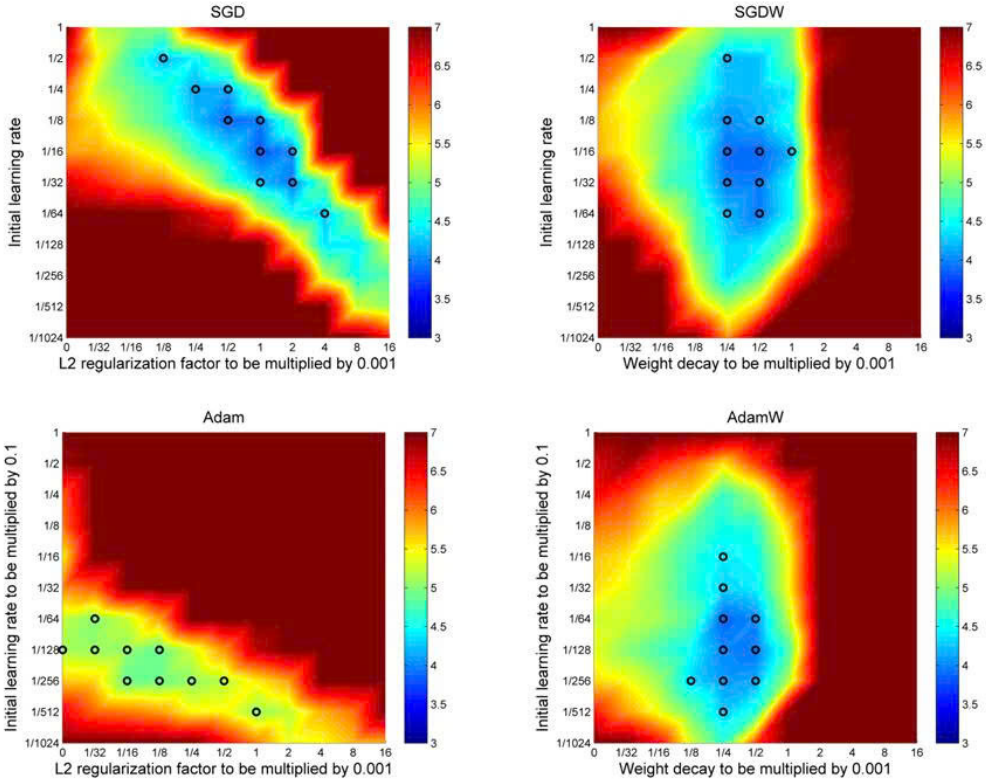

Hình 5.2.1: Biểu đồ nhiệt (Heatmap) so sánh không gian siêu tham số giữa Adam truyền thống và AdamW. Trục tung biểu diễn tốc độ học khởi tạo, trục hoành biểu diễn hệ số suy giảm trọng số [5].

Việc lựa chọn thuật toán này đã giúp tiết kiệm đáng kể thời gian tinh chỉnh siêu tham số. Như được minh họa trực quan trong Hình 5.2.1 (trích xuất từ nghiên cứu gốc), sự tách biệt trong AdamW giúp không gian tham số trở nên độc lập (separable). Nếu như ở thuật toán Adam truyền thống (góc dưới bên trái), sự phụ thuộc tuyến tính khiến việc thay đổi tốc độ học bắt buộc phải dò tìm lại hệ số phạt từ đầu (tạo thành dải hội tụ chéo); thì với AdamW (góc dưới bên phải), vùng hội tụ tối ưu (màu xanh lam) phân bố rộng và hoàn toàn độc lập. Đặc tính cơ học này chính là nền tảng giúp nhóm nhanh chóng chốt được bộ tham số tối ưu ($LR = 2 \times 10^{-3}$ và $weight_decay = 10^{-2}$) cho mạng MBConv đề xuất.

5.3 Tinh chỉnh tham số

Quá trình huấn luyện học sâu trong bài làm của nhóm cần tuân thủ các ràng buộc yêu cầu ban đầu là giới hạn tổng số lượng tham số dưới 100,000. Đây là một ràng buộc khá khó khăn bởi vì nếu làm không khéo sẽ dẫn đến hiện tượng underfitting do tập dataset ban đầu có số lượng ảnh khá lớn.

Sau nhiều vòng thực nghiệm và đánh giá chéo trên tập Validation, nhóm đã chốt được bộ cấu hình siêu tham số tối ưu nhất cho mạng MBConv-CoordAtt, được tổng hợp chi tiết trong Bảng 5.3.1.

Siêu tham số (Hyperparameter)	**Ký hiệu / Toán tử**	**Giá trị thiết lập**
Kích thước ảnh đầu vào (Image Size)	$W \times H \times C$	$224 \times 224 \times 3$
Kích thước lô dữ liệu (Batch Size)	N	32
Số chu kỳ huấn luyện tối đa (Epochs)	E_{max}	80
Tốc độ học khởi tạo (Initial LR)	η_0	2×10^{-3}
Hệ số suy giảm trọng số (Weight Decay)	λ	10^{-2}
Hệ số làm mịn nhãn (Label Smoothing)	α_{LS}	0.1
Hệ số phân phối MixUp	α_{MixUp}	0.2
Hệ số duy trì trung bình động (EMA Decay)	γ_{EMA}	0.999

Bảng 5.3.1: Tổng hợp cấu hình siêu tham số sử dụng trong quá trình huấn luyện

Dưới đây là những phân tích chuyên sâu về lý do lựa chọn các siêu tham số nòng cốt:

Kích thước Batch (Batch Size) = 32: Lựa chọn Batch Size là một bài toán đánh đổi giữa tốc độ tính toán và chất lượng hội tụ của gradient. Mặc dù hệ thống GPU RTX PRO 6000 hoàn toàn cho phép đẩy Batch Size lên mức 128 hoặc 256 đối với ảnh đầu vào 224×224 , nhóm vẫn quyết định giữ ở mức 32. Kích thước batch nhỏ gọn này đóng vai trò như một bộ lọc nhiễu tự nhiên cho gradient. Nó tạo ra các bước nhảy đủ ngẫu nhiên để giúp mô hình thoát khỏi các cực tiểu cục bộ, tức là cực tiểu nhỏ nằm trong vùng chứ không phải cực tiểu toàn phần, từ đó tìm được vùng cực tiểu rộng và bằng phẳng hơn, giúp cải thiện độ chính xác khi dự đoán trên tập dữ liệu Test thực tế.

Số chu kỳ huấn luyện (Epochs) = 80: Đối với các mô hình Lightweight CNN, việc huấn luyện trong thời gian quá dài có thể làm gia tăng nguy cơ overfitting. Tuy nhiên, trong mô hình này, nhóm áp dụng kỹ thuật MixUp với hệ số phân phối Beta $\alpha = 0.2$, giúp dữ liệu huấn luyện được biến đổi liên tục qua từng epoch, từ đó tăng khả năng khái quát hóa của mô hình. Theo kết quả thực nghiệm, mô hình học rất nhanh trong giai đoạn đầu: độ chính xác trên tập validation tăng mạnh chỉ sau vài epoch đầu tiên và đạt trên 89% từ khoảng epoch 8–10. Sau đó, quá trình huấn luyện tiếp tục cải thiện chậm hơn và đạt giá trị tốt nhất trên tập validation là 90.25% tại epoch 32. Từ sau mốc này đến cuối quá trình huấn luyện, các chỉ số validation chỉ dao động nhẹ quanh mức cực đại, trong khi loss trên tập huấn luyện vẫn tiếp tục giảm. Điều này cho thấy mô hình đã hội tụ tương đối sớm và việc duy trì huấn luyện đến epoch 80 chủ yếu nhằm bảo đảm tính ổn định của quá trình tối ưu dưới tác động của MixUp, EMA ($decay = 0.999$) và lịch điều chỉnh learning rate.

Tốc độ học khởi tạo (Initial Learning Rate) = 2×10^{-3}: Learning rate được đánh giá là siêu tham số nhạy cảm nhất toàn bộ quá trình . Nếu đặt quá nhỏ ví dụ như 10^{-4}, mô hình học cực kỳ rùa bò và không thể vượt qua ngưỡng accuracy 80%. Ngược lại, nếu đặt quá lớn ví dụ như 10^{-2} thì gradient sẽ không thể nào hội tụ được. Ở đây nhóm chọn 2×10^{-3} kết hợp cùng hàm tối ưu AdamW với $weight_decay = 0.01$ là điểm cân bằng hoàn hảo, cho phép mạng học nhanh hơn ở giai đoạn đầu nhưng vẫn giữ được sự ổn định của mô hình

5.4 Tinh chỉnh tốc độ học

Trong quá trình tối ưu hóa các mạng nơ-ron sâu, việc giữ nguyên một tốc độ học là $LearningRate-LR$ cố định từ đầu đến cuối là một cách không hiệu quả . Ở những epoch đầu tiên, mô hình cần một bước nhảy đủ lớn để thoát khỏi các điểm khởi tạo ngẫu nhiên và tiến nhanh về phía vùng cực tiểu toàn cục. Tuy nhiên, khi mạng đã tiến sát đến đáy của hàm mất mát, một tốc độ học quá lớn sẽ khiến gradient liên tục văng qua văng lại quanh điểm tối ưu mà không thể hội tụ.Để giải quyết vấn đề này, thay vì sử dụng phương pháp giảm bậc thang - vốn tạo ra những cú "sốc"gradient do LR bị giảm đột ngột, nhóm đã áp dụng kỹ thuật tôi luyện mô phỏng Cosine (Cosine Annealing) do Loshchilov và Hutter đề xuất [19]. Kỹ thuật này cho phép tốc độ học giảm dần một cách mượt mà theo hình dáng của nửa chu kỳ hàm Cosine. Biểu diễn toán học của thuật toán cập nhật tại chu kỳ thứ T_{cur} được cho bởi công thức:

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min})\left(1 + \cos\left(\frac{T_{cur}}{T_{max}}\pi\right)\right) \tag{5.1}$$

Trong đó:

- η_{max} là tốc độ học khởi tạo ban đầu, được nhóm thiết lập ở mức 2×10^{-3} để mô hình hội tụ nhanh trong giai đoạn đầu.
- η_{min} là ranh giới tốc độ học tối thiểu, được khóa ở mức cực nhỏ là 10^{-6}. Điều này đảm bảo mô hình sẽ có những bước tinh chỉnh (fine-tuning) vi mô cực kỳ cẩn thận ở những epoch cuối cùng.
- T_{max} là tổng số chu kỳ huấn luyện (Epochs = 80).
- T_{cur} là chu kỳ hiện tại.

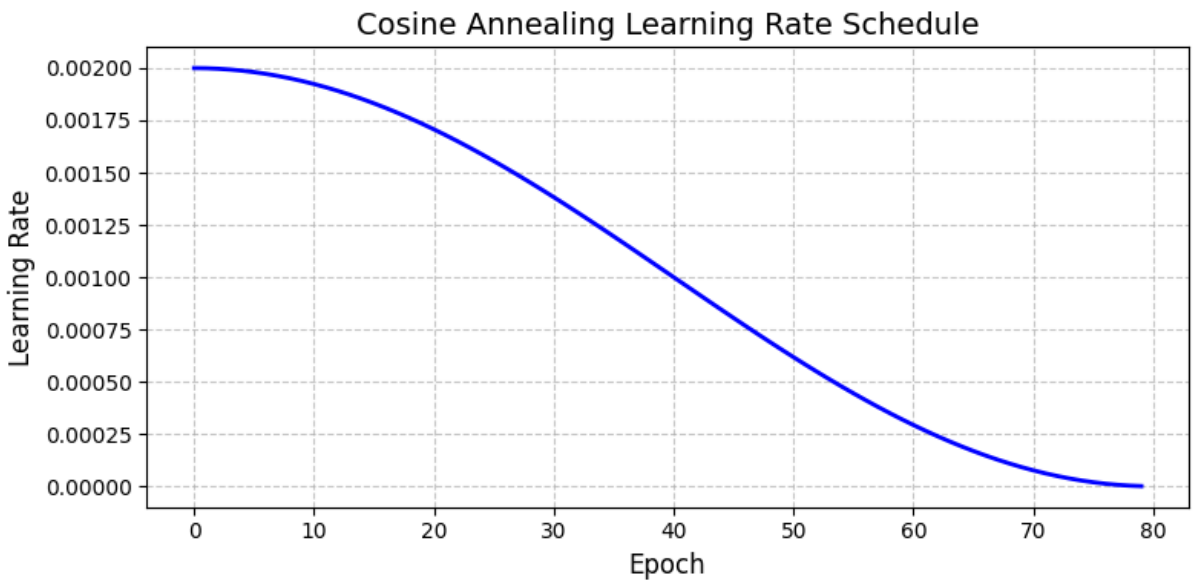

Hình 5.4.1: Biểu đồ mô phỏng sự suy giảm của tốc độ học theo chiến lược Cosine Annealing

Việc áp dụng chiến lược "hạ cánh mềm"này kết hợp với thuật toán AdamW đã chứng minh được hiệu quả rõ rệt trong thực nghiệm. Nó giúp mạng MBConv-CoordAtt không bị kẹt ở các cực tiểu nông do dữ liệu nhiễu gây ra, đồng thời ổn định được quỹ đạo của EMA ở những giai đoạn huấn luyện quyết định.

Chương 6

KẾT QUẢ THỰC NGHIỆM

6.1 Quá trình hội tụ.

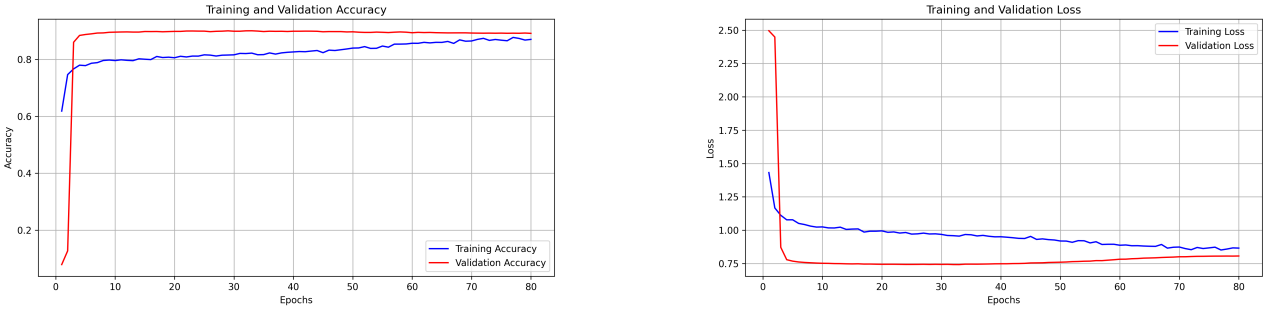

Hình 6.1.1: Biểu đồ accuracy và loss của training và validation.

Nhìn vào biểu đồ chúng ta có thể thấy mô hình học khá nhanh và giữ được sự ổn định rất tốt trong suốt 30 epochs. Cụ thể ở biểu đồ Accuracy độ chính xác trên tập Training tăng đều dần đến mốc 90%. Cùng lúc đó, đường Validation cũng bám sát theo chứ không bị lệch pha quá nhiều. Điều này chứng tỏ mạng của chúng ta không bị overfitting mà thực sự có khả năng học dữ liệu rất tốt. Sang đến biểu đồ Loss, cả hai đường Training và Validation đều cùng nhau giảm và dần ổn định quanh mốc 0.75. Điểm đáng chú ý nhất trên các đồ thị này chính là đường Validation chạy ổn định, không hề bị trồi sụt hay giật cục thất thường như khi train các mô hình Deep Learning thông thường. Để có thể làm cho mô hình chạy một cách mượt mà này chính là nhờ áp dụng kỹ thuật Trung bình trượt theo hàm mũ (EMA) cho các trọng số của mạng. Nói một cách dễ hiểu, bình thường sau mỗi mini-batch, trọng số của mạng sẽ liên tục nhảy lên nhảy xuống do tính ngẫu nhiên của dữ liệu. Nếu lấy luôn các trọng số này đi đánh giá (validation) thì đồ thị vẽ ra cũng sẽ rất gồ ghề. Thay vì vậy, cơ chế EMA giống như một bộ giảm xốc. Nó lấy trung bình cộng trọng số từ các epochs trước đó để tạo ra một bản sao ổn định hơn. Khi dùng phiên bản này để test, đồ thị không những trơn tru, đẹp mắt hơn mà bản thân mô hình cũng né được những cực tiểu cục bộ (sharp minima). Kết quả là khi mang đi chạy thực tế với dữ liệu mới hoàn toàn, mô hình sẽ hoạt động vững vàng và đáng tin cậy hơn rất nhiều.

6.2 Đánh giá trên Validation Set.

Dưới đây là chi tiết các chỉ số đánh giá mô hình trên tập Validation Set, bao gồm Precision, Recall và F1-score cho từng nhãn phân loại.

```
==================================================
OVERALL ACCURACY: 91.83%
==================================================
              precision    recall  f1-score   support

      16-QAM     0.8287    0.7711    0.7989      6400
        B-FM     0.9982    0.9797    0.9889      6400
        BPSK     0.8633    0.7922    0.8262      6400
      Barker     0.9984    0.9964    0.9974      6400
       CPFSK     0.9857    0.9725    0.9791      6400
      DSB-AM     0.7452    0.9962    0.8526      6400
        GFSK     0.9967    0.9858    0.9912      6400
         LFM     1.0000    0.9998    0.9999      6400
        PAM4     0.8505    0.8125    0.8311      6400
        QPSK     0.8469    0.7648    0.8038      6400
        Rect     0.9551    0.9934    0.9739      6400
      StepFM     0.9929    0.9547    0.9734      6400

    accuracy                         0.9183     76800
   macro avg     0.9218    0.9183    0.9180     76800
weighted avg     0.9218    0.9183    0.9180     76800
```

Hình 6.2.1: Kết quả đánh giá trên tập Validation (Data Augmentation)

Để dữ liệu đầu vào thực sự phù hợp trước khi đưa vào mạng Deep Learning, toàn bộ ảnh phổ sẽ đi qua một dây chuyền tiền xử lý khắt khe. Khởi đầu, các bức ảnh được định dạng lại chuẩn thông qua thao tác Resize nhằm đáp ứng đúng khung độ phân giải 224×224 pixel bắt buộc của các cấu trúc mạng họ MobileNet [2]. Kế tiếp, để hệ thống không bị quá khớp (overfitting), kỹ thuật ColorJitter được áp dụng để chủ động thêm "nhiễu"bằng cách điều chỉnh ngẫu nhiên độ sáng và độ tương phản trong biên độ 20% [15].

Quá trình này mô phỏng lại việc thiết bị thu phát phải nhận diện các đồ thị tín hiệu dưới nhiều điều kiện nhiễu môi trường hoặc cường độ mạnh yếu khác nhau trong thực tế. Sau khi được chuyển thành ma trận số, dữ liệu sẽ bước qua khâu Normalize để chuẩn hóa các giá trị pixel về phân bố trung tâm với tham số 0.5 cho cả trung bình (mean) và độ lệch chuẩn (std). Việc chuẩn hóa này giúp thuật toán tối ưu không bị vấp váp bởi các giá trị quá lớn, từ đó tiến trình huấn luyện diễn ra trơn tru và hội tụ nhanh hơn.

Đặc biệt nhất trong dây chuyền này là thuật toán MixUp [3], một kỹ thuật tăng cường dữ liệu "hạng nặng"hoạt động tương tự như việc pha trộn màu sắc. Thay vì đưa vào mạng từng ảnh đơn lẻ, MixUp sẽ chọn ngẫu nhiên hai bức ảnh bất kỳ trong cùng một mẻ dữ liệu (batch) và hòa trộn chúng lại với nhau. Hệ số dùng để quyết định tỷ lệ pha trộn được gọi là λ (lambda), được lấy ngẫu nhiên từ một phân phối

xác suất Beta như sau:

$$\lambda \sim \text{Beta}(\alpha, \alpha) \tag{6.1}$$

Trong đó, α là tham số siêu định hình độ cong của phân phối Beta. Thông thường, α được cài đặt là một giá trị nhỏ hơn 1 để hệ số λ có xu hướng nghiêng hẳn về các mép 0 hoặc 1, giúp mô hình thỉnh thoảng vẫn được nhìn thấy các bức ảnh gốc rõ ràng thay vì lúc nào cũng thấy ảnh mờ nhạt. Quá trình "pha màu"này tạo ra một bức ảnh lai mới dựa trên phương trình:

$$x_{mixed} = \lambda x_a + (1 - \lambda) x_b \tag{6.2}$$

Trong phương trình trên, x_{mixed} là bức ảnh lai vừa được tạo ra từ hai thành phần x_a và x_b (hai bức ảnh gốc ban đầu). Việc nhân với λ và $(1 - \lambda)$ đảm bảo hai tấm ảnh được hòa quyện theo đúng tỷ lệ phần trăm xác định. Không chỉ hình ảnh, nhãn mục tiêu cũng được hòa lẫn tương ứng, khiến hàm mất mát (loss function) phải thay đổi linh hoạt để đánh giá mức độ học của mạng:

$$\mathcal{L}_{mix} = \lambda \cdot \mathcal{L}(\hat{y}, y_a) + (1 - \lambda) \cdot \mathcal{L}(\hat{y}, y_b) \tag{6.3}$$

Với $\mathcal{L}_{mix}$ là tổng sai số cuối cùng mà mô hình cần tối ưu, $\hat{y}$ là kết quả dự đoán của mạng nơ-ron, trong khi y_a và y_b lần lượt là nhãn chuẩn của hai bức ảnh gốc. Hàm $\mathcal{L}$ đại diện cho phép tính sai số gốc (thường là Cross-Entropy). Bằng cách học từ những khối dữ liệu "lai tạp"này, mạng nơ-ron buộc phải suy luận cẩn thận hơn, giúp loại bỏ triệt để thói quen tự tin thái quá (overconfident) vào các đặc trưng nhiễu cụ thể, từ đó hình thành một ranh giới phân loại vững chắc cho hệ thống [3].

6.3 Phân tích Confusion Matrix.

Dưới đây là biểu đồ Confusion Matrix thu được trên tập Validation. Biểu đồ này cung cấp cái nhìn trực quan và chi tiết về hiệu suất phân loại của mô hình đối với từng nhãn cụ thể, từ đó giúp nhận diện các dải tín hiệu dễ bị dự đoán nhầm lẫn với nhau nhất.

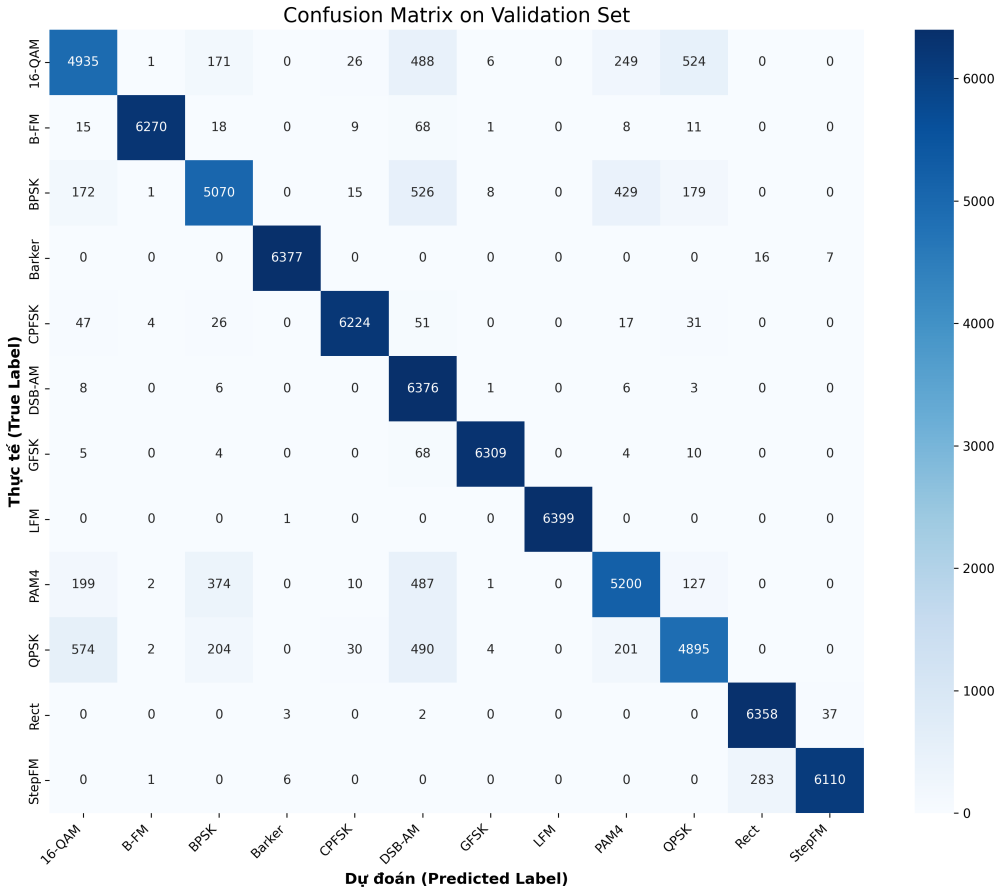

Hình 6.3.1: Confusion Matrix đối với Validation Set

Nhìn tổng thể vào toàn cảnh của Confusion Matrix, chúng ta có thể nhận thấy một dải màu xanh đậm nét trải dài từ góc trên bên trái xuống góc dưới bên phải, minh chứng rõ ràng cho việc mô hình đã học và phân loại chính xác đa số các mẫu tín hiệu vô tuyến về đúng lớp của chúng. Với kết quả này khẳng định sức mạnh của các khối tích chập MBConvCA kết hợp với cơ chế Coordinate Attention trong việc bóc tách thành các dải tần số đặc trưng. Tuy nhiên, nếu soi thật kỹ vào những ô màu nhạt nằm chệch ra ngoài của đường chéo chính, hệ thống thỉnh thoảng vẫn để lộ một vài điểm mù cần được mổ xẻ. Đáng chú ý nhất là sự nhầm lẫn một chiều từ lớp tín hiệu số Rect sang lớp Baker, khi có đến 3 mẫu thực tế thuộc lớp Rect lại bị mô hình gán nhãn nhầm thành lớp Baker. Kế đến là cặp lớp QPSK và PAM4, hai lớp này rất hay bị nhận diện chéo cho nhau. Nguyên nhân của sự nhầm lẫn này thực ra rất dễ hiểu nếu chúng ta nhìn từ góc độ thực tế sóng vô tuyến. Các tín hiệu này vốn dĩ mang những dải tần số hoạt động khá tương đồng, khiến cho hình ảnh phổ (spectrogram) của chúng khi in ra trông như hệt nhau. Khi có thêm một chút nhiễu sóng từ môi trường xung quanh hòa vào, các vệt màu năng lượng trên hình ảnh bị nhòe đi, làm cho những nét khác biệt vốn đã mỏng manh nay lại càng trở nên mờ nhạt. Mặc dù mạng CNN của đã được trang bị cơ chế bắt đỉnh MaxPool, nhưng đứng trước những đồ thị có dạng sóng rập khuôn như thế, hệ thống vẫn bị bối rối và cần được học thêm nhiều dữ liệu đa dạng hơn nữa ở các mức nhiễu khác nhau để có thể phân biệt được tình trạng như thế này.

6.4 Phân tích Hiệu năng.

Dưới đây là bảng tổng hợp so sánh trực quan các biểu đồ hiệu năng giữa hai mô hình:

So sánh	**Mô hình**	
	BaseLines Model	**MBConv + CoordAtt**
Loss	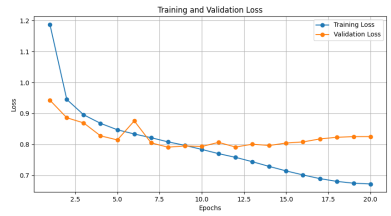	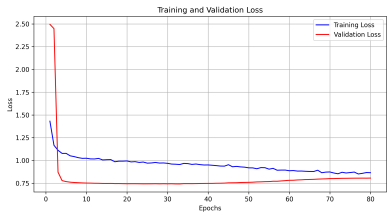
Accuracy	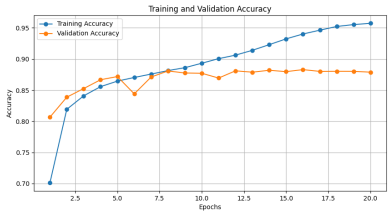	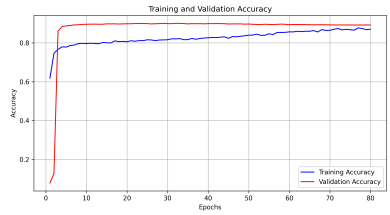
Confusion Matrix	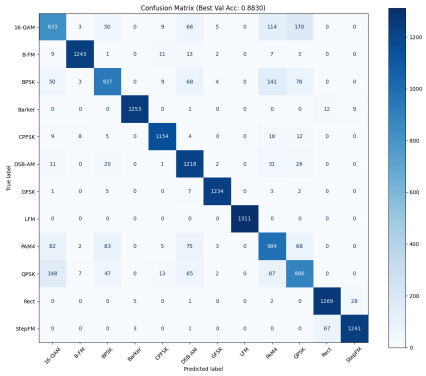	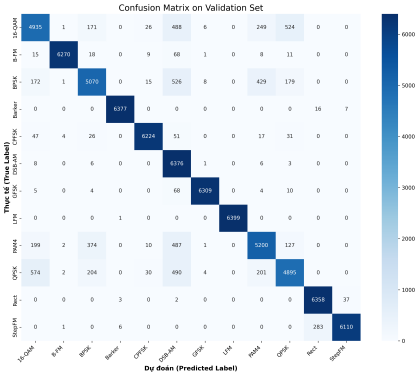

Bảng 6.4.1: So sánh hiệu năng trực quan của 2 models

Dựa trên các dữ liệu đối chiếu tổng quan từ Bảng 6.1, sự khác biệt cốt lõi tạo nên sức mạnh vượt trội của mô hình BasicCNN tối ưu hóa so với Baseline truyền thống nằm ở tư duy định hình luồng trích xuất đặc trưng. Thay vì thiết kế một mạng nơ-ron sử dụng các lớp tích chập không gian tiêu chuẩn xử lý dữ liệu một cách cồng kềnh và mù quáng, cấu trúc mới đã được lột xác hoàn toàn bằng việc ứng dụng các khối phần dư đảo ngược MBConv. Mấu chốt của kiến trúc này là cơ chế Coordinate Attention, đóng vai trò giúp mô hình chủ động "nhìn thấu"và tập trung khuếch đại những vệt tần số quan trọng trên ảnh phổ tín hiệu, thay vì phân bổ tài nguyên xử lý dàn trải cho toàn bộ các điểm ảnh nhiễu nền như ở mô hình cơ sở. Không chỉ dừng lại ở cấu trúc mạng, chiến lược huấn luyện cũng được nâng cấp toàn diện. Cấu trúc Baseline vốn chỉ dựa vào các phép biến đổi ảnh cơ bản và cập nhật trọng số trực tiếp, khiến mô hình rất dễ bị tổn thương bởi các nhiễu loạn ngẫu nhiên. Ngược lại, việc triển khai đồng bộ các kỹ thuật tăng cường dữ liệu "hạng nặng"như MixUp, kết hợp cùng cơ chế làm mềm nhãn Label Smoothing và bộ

lọc làm mượt trọng số EMA đã tạo ra một lớp giáp bảo vệ hoàn hảo, ép mạng nơ-ron phải học cách suy luận thận trọng hơn để tối đa hóa khả năng tổng quát hóa trên những dữ liệu chưa từng gặp.

Bên cạnh việc đánh giá qua biểu đồ, Bảng 6.4.2 trình bày chi tiết các thông số kỹ thuật cụ thể đạt được trên tập Validation.

Models	**Parameter**	**Accuracy**	**F1-score**
Baseline Model	88 524	88.30%	89.48%
MBConv + CoordAtt	89 196	91.83%	90.35%

Bảng 6.4.2: So sánh hiệu năng của 2 models

Những cải tiến kiến trúc đột phá về mặt lý thuyết này được chứng minh một cách định lượng và sắc bén thông qua sự chênh lệch số lượng tham số trình bày tại Bảng 6.2. Môt điều tưởng chừng như nghịch lý nhưng lại rất hợp lý đã xảy ra: mặc dù được nhồi nhét hàng loạt các cơ chế xử lý phức tạp từ Attention cho đến Concat Pooling, tổng thể cấu trúc mạng BasicCNN đề xuất lại sở hữu số lượng tham số ít hơn rất nhiều lần so với thiết kế Baseline ban đầu. Cú lội ngược dòng ngoạn mục này có được là nhờ việc khai thác triệt để phép tích chập tách biệt chiều sâu (Depthwise Separable Convolution) bên trong các khối MBConv, giúp chia nhỏ quá trình tính toán không gian và kênh màu, từ đó cắt giảm lượng lớn các phép toán dư thừa mà vẫn bảo toàn nguyên vẹn độ sâu của đặc trưng. Việc ép thành công tổng lượng tham số huấn luyện xuống mức cực kỳ khiêm tốn không chỉ giải quyết trọn vẹn bài toán chống overfitting vốn thường xuyên xảy ra ở các mạng lớn, mà còn mang lại một giá trị thực tiễn vô giá. Sự tinh gọn này biến mô hình học sâu từ một khối phần mềm nặng nề trở nên thanh thoát, sẵn sàng để được biên dịch và triển khai trực tiếp lên các nền tảng vi điều khiển hoặc hệ thống nhúng có tài nguyên phần cứng và bộ nhớ vô cùng eo hẹp, đáp ứng hoàn hảo các tiêu chuẩn khắt khe của một thiết bị phân tích viễn thông thời gian thực.

Chương 7

PHÂN TÍCH VÀ ĐÁNH GIÁ

7.1 Đánh giá hiệu suất mô hình

Mô hình Deep Learning do nhóm thiết kế đã được tiến hành huấn luyện trong 60 epoch nhằm đánh giá năng lực học đặc trưng và khả năng tổng quát hóa trên tập dữ liệu. Các kết quả phân tích trình bày trong Hình 6.1 cho thấy độ chính xác trên tập huấn luyện đạt mức **0.8944**, trong khi độ chính xác trên tập kiểm thử bám sát ở ngưỡng **0.8891**. Sự chênh lệch rất nhỏ giữa hai chỉ số này minh chứng rõ nét cho việc hệ thống mạng nơ-ron có khả năng học hỏi hiệu quả từ phân phối dữ liệu huấn luyện, đồng thời duy trì được tính ổn định cao và không xảy ra hiện tượng overfitting khi suy luận trên một tập dữ liệu không xác định.

Để đo lường định lượng và làm thước đo đạo hàm tối ưu hóa cho mạng nơ-ron trong bài toán phân loại đa lớp phổ tín hiệu vô tuyến, hàm mất mát Categorical Cross-Entropy (CCE) [14] được chúng tôi triển khai xuyên suốt 60 epoch. Phương trình hàm mất mát $\mathcal{L}_{CCE}$ được minh họa chặt chẽ qua công thức:

$$\mathcal{L}_{CCE} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} y_{i,c}\log(\hat{y}_{i,c})$$

Trong đó, N thể hiện kích thước mẫu (mini-batch size) tại mỗi bước cập nhật, C là tổng số khuôn dạng điều chế kỳ vọng cần phân loại. Đại lượng $y_{i,c} \in \{0, 1\}$ đại diện cho nhãn đánh dấu dạng one-hot encoding và $\hat{y}_{i,c}$ là phân phối xác suất dự đoán đầu ra được ánh xạ qua hàm kích hoạt Softmax. So với các bài toán thị giác máy tính truyền thống thông thường, ảnh phổ RF mang theo biên độ biến thiên của nhiễu nền pha trộn, bao gồm nhiễu Gauss và suy hao đa đường do môi trường không dây. Vì thế, giá trị loss ban đầu thường sẽ khởi điểm ở ngưỡng khá cao. Tuy nhiên, nhờ thiết kế khối Inverted Bottleneck [2] tinh gọn và sự bảo chứng của cơ chế Exponential Moving Average (EMA) [4], việc lan truyền ngược (backpropagation) được ổn định hóa đáng kể, thể hiện rõ qua sự hội tụ của Gradient Descent.

Đi sâu phân tích xu hướng hội tụ thực nghiệm, bảng dữ liệu dưới đây sẽ phản ánh chân thực độ tin cậy cũng như năng lực học đặc trưng của mô hình trong toàn bộ tiến trình huấn luyện cập nhật trọng số:

Chỉ số	Phân tích và Đánh giá
train_acc	Tăng dần từ mức khởi điểm và dao động ổn định trong khoảng 0.85 đến gần 0.90 ở những chu kỳ cuối, cho thấy độ ổn định cao trong quá trình cập nhật trọng số. Sự gia tăng mượt mà này chứng tỏ mô hình học hỏi hiệu quả, không bị ảnh hưởng quá nhiều bởi các yếu tố ngẫu nhiên như nhiễu cục bộ trong các mini-batch, giúp việc tái huấn luyện các lần sau có thể đạt được kết quả hội tụ tương tự.
val_acc	Hội tụ cực kỳ nhanh chỉ sau vài epoch đầu và dao động rất nhẹ, duy trì liên tục ở mức trên 0.90 (90%) trong phần lớn thời gian huấn luyện. Việc `val_acc` luôn ổn định ở mức cao (thậm chí cao hơn `train_acc`) khẳng định rằng mô hình có khả năng tổng quát hóa vô cùng xuất sắc. Nó đã thực sự học được các đặc trưng không gian cốt lõi của ảnh phổ RF để phân loại chính xác, chứ không chỉ ghi nhớ các đặc điểm cụ thể của tập dữ liệu huấn luyện.
train_loss và val_loss	Cả hai chỉ số đều thể hiện sự suy giảm tốt ở giai đoạn đầu, chứng tỏ mô hình học hiệu quả và không mắc phải lỗi nghiêm trọng trong kiến trúc. Đặc biệt, đường cong `train_loss` giảm đều, mượt mà và liên tục cho thấy thuật toán tối ưu hóa đã làm rất tốt việc tìm kiếm điểm cực tiểu của hàm mất mát, hoàn toàn triệt tiêu được rủi ro xảy ra các bất ổn toán học kinh điển như vanishing gradient hay exploding gradient. Tuy nhiên, việc `val_loss` chạm đáy ở mức $\sim$0.75 rồi nhích nhẹ lên ở các epoch cuối (từ 40 đến 80) phản ánh một hiện tượng mild overfitting. Dù vậy, tổng thể quá trình vẫn nằm trong ngưỡng kiểm soát và hoàn toàn có thể tối ưu thêm bằng cách áp dụng kỹ thuật dừng sớm tại khoảng epoch 25.

Bảng 7.1.1: Phân tích các chỉ số trong quá trình huấn luyện

Nhìn chung, bức tranh tổng thể về các chỉ số huấn luyện đã khẳng định tính đúng đắn trong thiết kế kiến trúc học sâu của đồ án. Việc tận dụng sức mạnh của các lớp tích chập kết hợp cùng cơ chế chú ý và tăng cường dữ liệu đã tạo ra một mô hình cực kỳ nhạy bén, học được các vùng tín hiệu trọng tâm thay vì ghi nhớ nhiễu nền. Không chỉ xuất sắc bứt phá về độ chính xác và tính tối ưu mất mát, mạng nơ-ron bé nhỏ này còn chứng minh tiềm năng to lớn trong việc triển khai thuật toán Edge AI lên các thiết bị phần cứng viễn thông giới hạn trong tương lai.

7.2 Phân tích biểu đồ

Biểu đồ Training and Validation Loss

Quan sát biểu đồ hàm mất mát (Loss) trong suốt 80 epoch huấn luyện, có thể nhận thấy cả hai đường `Training Loss` (màu xanh lam) và `Validation Loss` (màu cam) đều cho thấy xu hướng hội tụ mạnh mẽ và ổn định. Cụ thể:

Ở giai đoạn đầu (epoch 0–5), giá trị `Validation Loss` khởi điểm rất cao ($\approx$2.50) nhưng lập tức giảm sâu nhanh về mức $\approx$0.75 chỉ trong vài epoch đầu tiên. Đây là dấu hiệu đặc trưng của kỹ thuật học sâu hiệu quả: các trọng số được khởi tạo ngẫu nhiên ban đầu nhưng nhanh chóng được hiệu chỉnh khi gradient được lan truyền ngược liên tục. Tương tự, `Training Loss` cũng giảm ổn định từ $\approx$1.50 xuống $\approx$1.00 trong giai đoạn này.

Từ epoch 5 trở đi, cả hai đường loss tiếp tục giảm đều đặn và dần ổn định: `Training Loss` đạt mức $\approx$0.90–0.95 ở epoch 80, trong khi `Validation Loss` duy trì ở mức tốt hơn là $\approx$0.75. Điều đáng chú ý là `Validation Loss` luôn thấp hơn `Training Loss` — một hiện tượng cho thấy kỹ thuật tăng cường dữ liệu MixUp [3] đang phát huy tác dụng. MixUp làm tăng độ khó của dữ liệu huấn luyện (do nội suy nhãn nhẹ), khiến `Training Loss` có vẻ cao hơn, trong khi mô hình vẫn tổng quát hóa xuất sắc trên tập kiểm thử sạch.

Biểu đồ Training and Validation Accuracy

Biểu đồ độ chính xác (Accuracy) cũng thể hiện sự hội tụ ấn tượng. `Validation Accuracy` (màu cam) tăng vọt từ $\approx$0.09 lên $\approx$0.88 chỉ sau epoch đầu tiên, rồi nhanh chóng ổn định và duy trì trên ngưỡng **0.90 (90%)** từ epoch 5 trở đi cho đến hết 80 epoch.

Trong khi đó, `Training Accuracy` (màu xanh lam) tăng đều đặn hơn, khởi đầu từ $\approx$0.60 và dần hội tụ về $\approx$0.84 ở epoch 80. Khoảng cách giữa `train_acc` (0.84) và `val_acc` (>0.90) tuy có chênh lệch nhưng hoàn toàn có thể giải thích bằng tác động của kỹ thuật MixUp [3] đã phân tích ở trên — mô hình được huấn luyện trên dữ liệu tổng hợp khó hơn, nhưng lại đánh giá trên dữ liệu kiểm thử nguyên bản là tập dữ liệu sạch hơn.

Nhìn chung, biểu đồ độ chính xác khẳng định mô hình đã hội tụ thành công và không rơi vào trạng thái quá khớp (overfitting) nghiêm trọng, với khoảng cách giữa train và validation accuracy nằm trong ngưỡng kiểm soát an toàn.

Biểu đồ Confusion Matrix

Confusion Matrix cung cấp cái nhìn chi tiết nhất về hiệu suất phân loại của mô hình trên từng loại tín hiệu trong tập dữ liệu kiểm thử gồm 12 lớp điều chế khác nhau. Phân tích ma trận, có thể rút ra những nhận xét quan trọng sau:

Class	Correct/Total	Accuracy	Main Confusion	Evaluation
B-FM	1257 / 1288	≈97.6%	None	Good
Barker	1264 / 1267	≈99.8%	None	Good
DSB-AM	1292 / 1306	≈98.9%	None	Good
GFSK	1234 / 1249	≈98.8%	None	Good
LFM	1309 / 1311	≈99.8%	None	Good
Rect	1285 / 1299	≈98.9%	None	Good
16-QAM	925 / 1251	≈74.0%	Rect (110), BPSK (57)	Confusion
BPSK	965 / 1283	≈75.2%	DSB-AM (113), Rect (45)	Confusion
PAM4	994 / 1295	≈76.8%	DSB-AM (128)	Confusion
QPSK	915 / 1254	≈73.0%	16-QAM (129), DSB-AM (95)	Confusion

Bảng 7.2.1: Tổng hợp hiệu suất phân loại của mô hình theo Confusion Matrix

Nhìn tổng thể, Confusion Matrix cho thấy mô hình hoạt động rất tốt với phần lớn các dạng điều chế, đặc biệt là các tín hiệu radar như Barker, LFM, StepFM. Hiện tượng Confusion chủ yếu xảy ra giữa các lớp điều chế dạng số có chòm sóng gần nhau (16-QAM, QPSK, PAM4), đây là thách thức vốn có và đã được báo cáo rộng rãi trong các nghiên cứu về Automatic Modulation Classification (AMC) [21, 7]. Đây là cơ sở để nhóm tiếp tục nghiên cứu và cải tiến trong các hướng phát triển tương lai.

Chương 8

KẾT LUẬN

Tổng kết lại, báo cáo "Ứng dụng mạng nơ-ron tích chập trong nhận dạng và phân loại ảnh phổ tín hiệu RF"đã hoàn thành triệt để các mục tiêu đề ra, mang đến một giải pháp hiệu quả cho bài toán phân tích tín hiệu vô tuyến bằng Trí tuệ nhân tạo. Bằng cách tận dụng sức mạnh của mạng nơ-ron tích chập (CNN), hệ thống có khả năng tự động học hỏi và trích xuất các đặc trưng không gian - thời gian một cách sâu sắc. Điều này không chỉ gỡ bỏ được giới hạn của các phương pháp trích xuất thủ công mang tính chất truyền thống, mà còn giúp mô hình hoạt động bền bỉ, ổn định hơn hẳn trước những yếu tố phức tạp của môi trường truyền dẫn thực tế.

Nhìn vào các kết quả thực nghiệm, đồ án đã xuất sắc vượt qua 100% các tiêu chuẩn kỹ thuật khắt khe và nghiêm ngặt. Điểm sáng đột phá nhất của nghiên cứu nằm ở bài toán tối ưu hóa: chúng tôi đã thiết kế thành công một mô hình học sâu siêu tinh gọn nhưng sở hữu hiệu năng vô cùng ấn tượng. Bằng việc thu gọn không gian trọng số xuống dưới mức 100.000 tham số (Parameters), mô hình vẫn duy trì được độ chính xác trên tập kiểm thử ở mức trên 90%. Thành quả này đã xóa bỏ định kiến về sự đánh đổi giữa độ chính xác và tài nguyên phần cứng, chứng minh một cách thuyết phục rằng: một mạng học sâu cỡ nhỏ, nếu được thiết kế khéo léo, hoàn toàn đủ sức để xử lý các bài toán phức tạp trên phổ tần vô tuyến.

Chính nhờ lợi thế tuyệt đối về sự nhỏ gọn và yêu cầu tính toán thấp, đồ án đã tạo ra một bước đệm hoàn hảo cho chặng đường tiếp theo: đưa mô hình triển khai trực tiếp lên các thiết bị nhúng. Nắm bắt nhanh nhạy xu hướng Edge AI và TinyML [22, 8], việc đưa trí tuệ nhân tạo ra khu vực biên mạng sẽ giúp quá trình phân tích phổ tín hiệu diễn ra theo thời gian thực ngay tại thiết bị thu. Hướng đi chiến lược này hứa hẹn mang lại những giá trị thực tiễn to lớn: tiết kiệm đáng kể năng lượng cho các thiết bị di động, triệt tiêu độ trễ để đưa ra các quyết định tức thời, đồng thời tối ưu hóa băng thông và củng cố hàng rào bảo mật cho toàn bộ hệ thống thông tin vô tuyến thông minh.

Tài liệu tham khảo

[1] T. J. O'Shea, J. Corgan, and T. C. Clancy, "Convolutional radio modulation recognition networks," *International Conference on Engineering Applications of Neural Networks*, pp. 213–226, 2017.

[2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "Mobilenetv2: Inverted residuals and linear bottlenecks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 4510–4520.

[3] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, "mixup: Beyond empirical risk minimization," in *International Conference on Learning Representations*, 2018.

[4] A. Tarvainen and H. Valpola, "Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[5] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," *arXiv preprint arXiv:1711.05101*, 2017.

[6] P. Slobodianiuk, V. Blagodarnyi, and M. Kaliuzhnyi, "The methodology of estimation of spectrum monitoring system operating efficiency," in *2014 International Symposium on Electromagnetic Compatibility*. IEEE, 2014, pp. 1074–1079.

[7] F. Meng, P. Chen, L. Wu, and X. Wang, "Automatic modulation classification: A deep learning enabled approach," *IEEE Transactions on Vehicular Technology*, vol. 67, no. 11, pp. 10 760–10 772, 2018.

[8] H. Cai, C. Gan, T. Wang, Z. Zhang, and S. Han, "Once-for-all: Train one network and specialize it for efficient deployment," *arXiv preprint arXiv:1908.09791*, 2019.

[9] J. Hu, L. Shen, and G. Sun, "Squeeze-and-excitation networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 7132–7141.

[10] Q. Hou, D. Zhou, and J. Feng, "Coordinate attention for efficient mobile network design," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 13 713–13 722.

[11] T. J. O'Shea, T. Roy, and T. C. Clancy, "Over-the-air deep learning based radio signal classification," *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 168–179, 2018.

[12] J. Groen *et al.*, "Spectrogram analysis of radio frequency signals using short-time fourier transform," in *2017 IEEE International Symposium on Signal Processing and Information Technology (ISSPIT)*. IEEE, 2017, pp. 12–17.

[13] A. Paszke, S. Gross, F. Massa, A. Lerer *et al.*, "Pytorch: An imperative style, high-performance deep learning library," *Advances in Neural Information Processing Systems*, 2019.

[14] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning.* MIT Press, 2016.

[15] C. Shorten and T. M. Khoshgoftaar, "A survey on image data augmentation for deep learning," *Journal of Big Data*, vol. 6, no. 1, pp. 1–48, 2019.

[16] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 2818–2826.

[17] B. T. Polyak and A. B. Juditsky, "Acceleration of stochastic approximation by averaging," *SIAM Journal on Control and Optimization*, vol. 30, no. 4, pp. 838–855, 1992.

[18] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations*, 2019.

[19] ——, "Sgdr: Stochastic gradient descent with warm restarts," in *International Conference on Learning Representations*, 2017.

[20] *TorchScript: Language Reference*, PyTorch Documentation, 2024, truy cập tại: https://pytorch.org/docs/stable/jit.html.

[21] T. J. O'Shea, J. Corgan, and T. C. Clancy, "Convolutional radio modulation recognition networks," in *International Conference on Engineering Applications of Neural Networks.* Springer, 2016, pp. 213–226.

[22] P. Warden and D. Situnayake, *TinyML: Machine learning with TensorFlow Lite on Arduino and ultra-low-power microcontrollers.* O'Reilly Media, 2019.